



Aplikasi Convolutional Neural Network dan Decision Tree pada Diagnosa Penyakit Paru Obstruktif Kronis dengan Data Suara

Dosen Pembimbing:

- Dr. Nuning Nuraini, S.Si, M.Si

Dosen Penguji :

- Rudy Kusdiantara, S.Si., M.Si., Ph.D
- Dr. Dewi Handayani, S.Si., M.Si.

Steven Alexander Liong
10119080

P P O K

Penyakit Paru Obstruktif Kronis

Jenis penyakit paru-paru yang ditandai dengan kerusakan permanen pada jaringan di paru-paru, sehingga sulit bernapas, seringkali disebut sebagai emfisema atau bronkitis kronik.



Penyakit paling Mematikan di Dunia
menurut WHO

Penyebab

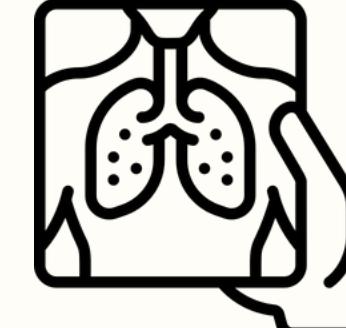
1. paparan tembakau dari perokok
2. paparan pekerjaan terhadap debu, asap atau bahan kimia;
3. polusi udara dalam ruangan

DIAGNOSA PPOK



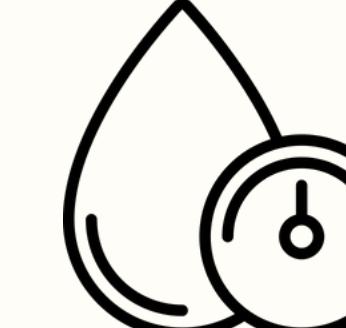
SPIROMETRI

Mengetahui kerja
dari paru-paru



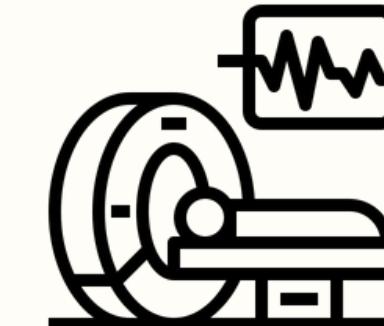
X-RAY

Gambar paru-paru
untuk diagnosa
dokter



TES GAS DARAH ARTERI

Mengetahui level
oksigen dalam
darah.



CT - SCAN

Gambar paru-paru
yang lebih akurat.

Penggunaan Metode Tradisional?

! Pasien Masalah
Jantung / Pasca
Operasi Jantung

! Sesak napas,
mual, dan pusing

! Radiasi

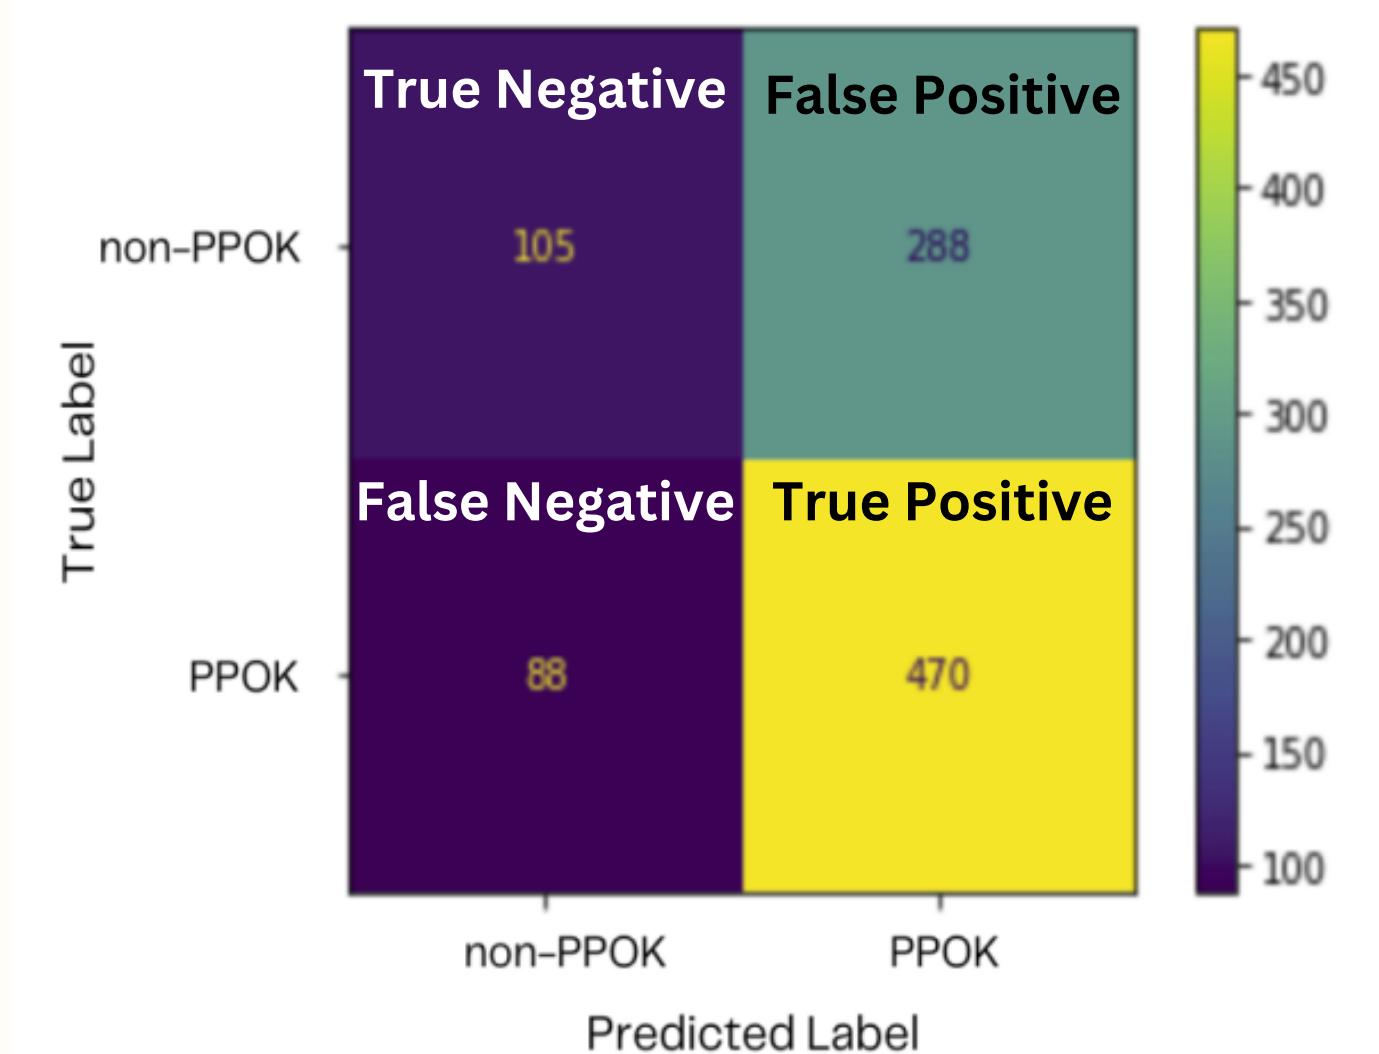
HASIL SEBELUMNYA

INSTITUT TEKNOLOGI BANDUNG



MODEL CONVOLUTIONAL NEURAL NETWORK

Nilai Prediksi	<i>Precision</i>	<i>Recall</i>	<i>F1-Score</i>	<i>Akurasi</i>
Memiliki PPOK	62%	84%	71.3%	60%
Tidak memiliki PPOK (non-PPOK)	54%	27%	36%	



$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

$$F1 Score = 2 \times \frac{\text{recall} \times \text{precision}}{\text{recall} + \text{precision}}$$

Rumusan Masalah

1. Bagaimana cara untuk mendapatkan model deteksi PPOK yang lebih baik dari model Convolutional Neural Network (CNN) sebelumnya?
2. Diantara model Convolutional Neural Network (CNN) dengan model Decision Tree, model manakah yang memberikan prediksi PPOK yang lebih baik?
3. Bagaimana mengetahui fitur apa saja yang paling mempengaruhi seseorang didiagnosa memiliki PPOK ?

Tujuan

1. Menggunakan model Decision Tree dengan metode ekstraksi data tabular pada data suara.
2. Membandingkan hasil model Convolutional Neural Network (CNN) dengan model Decision Tree menggunakan metrik evaluasi.
3. Menggunakan metode permutation feature importances dan bentuk pengambilan keputusan dalam model Decision Tree .

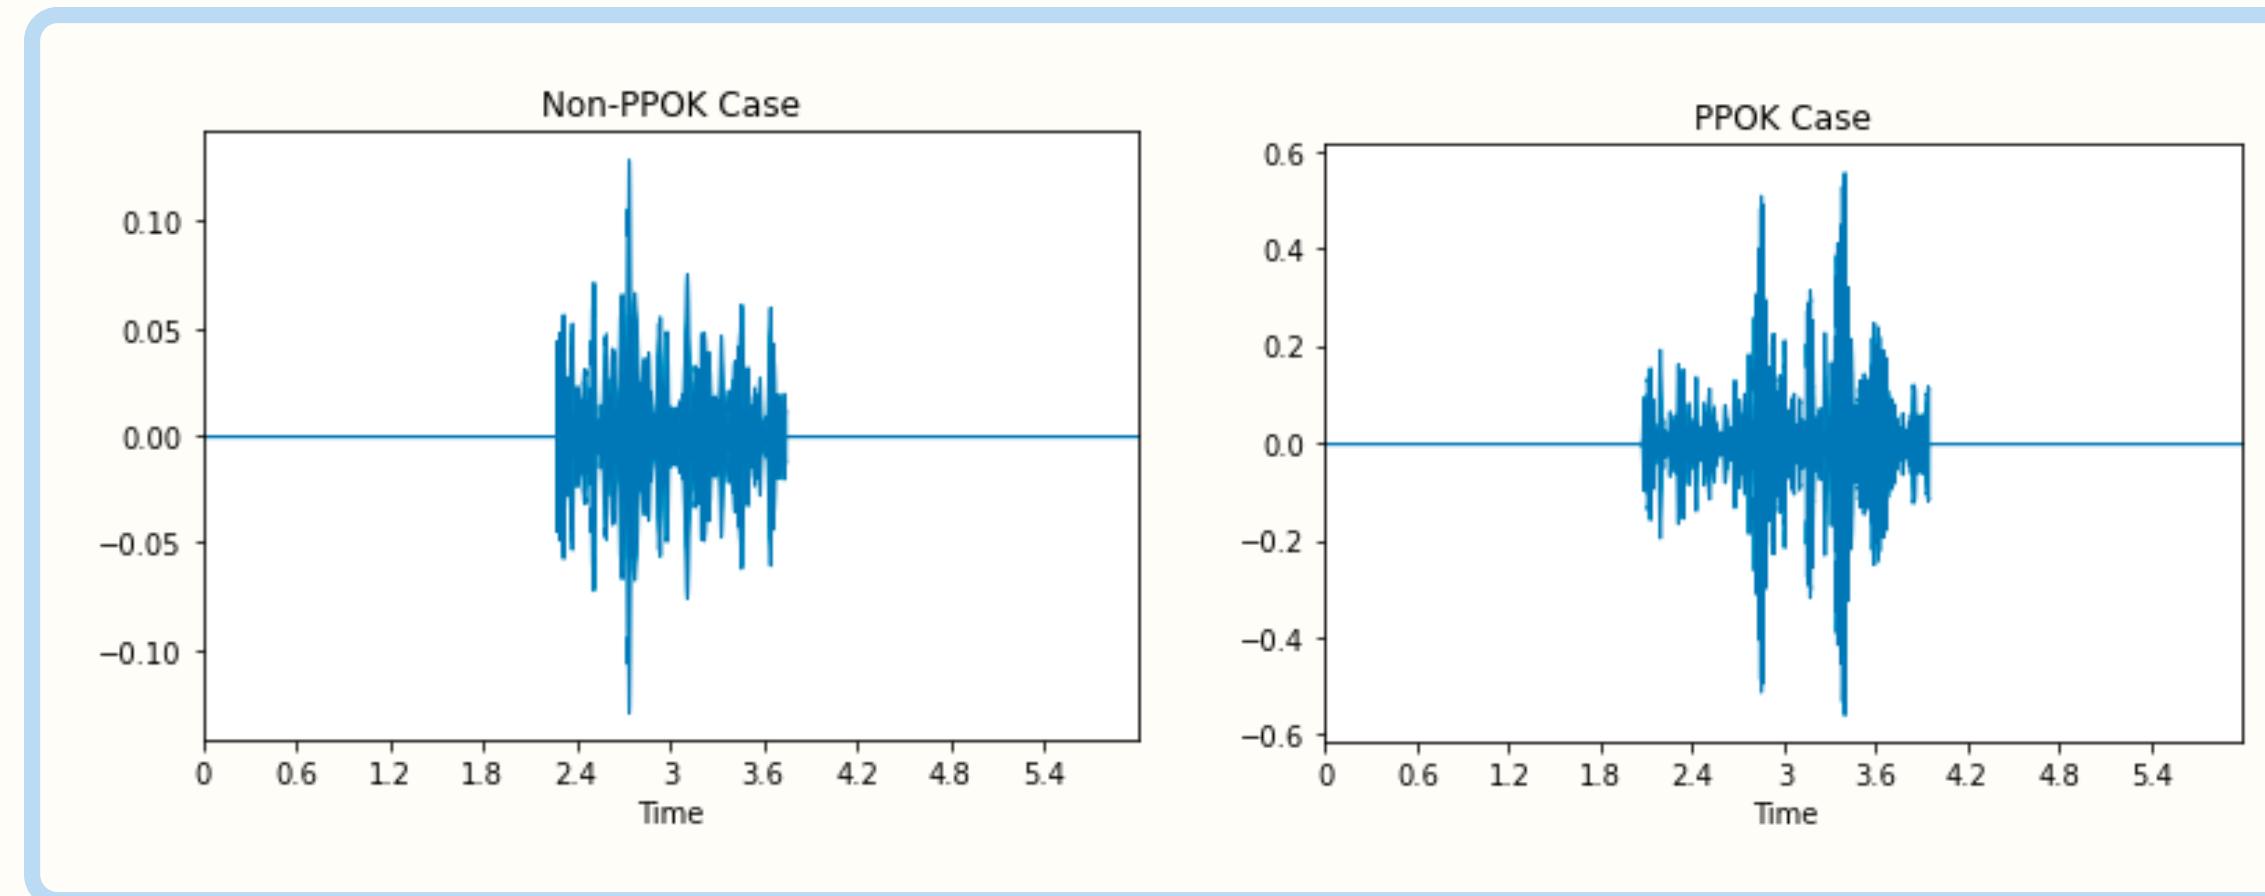
DATA

INSTITUT TEKNOLOGI BANDUNG

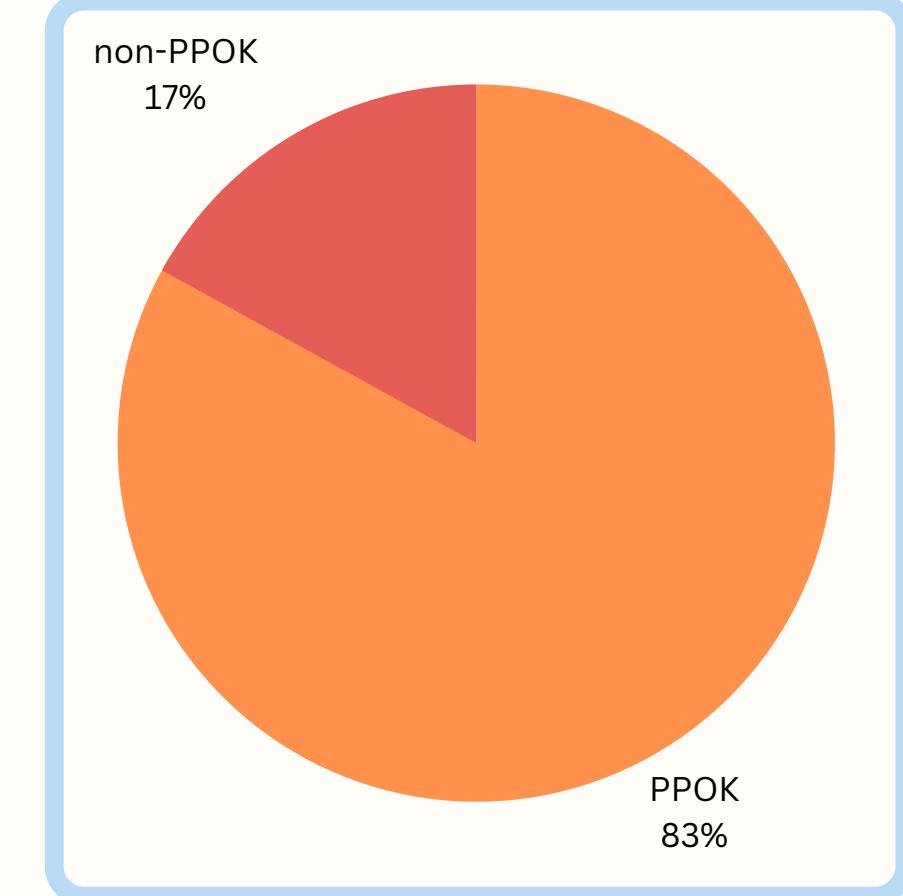


Terdiri dari :

- 920 file audio (.wav) suara pernafasan pasien
- 920 text file (.txt) berisi rincian data suara
- satu text file (.txt) berisi diagnosis setiap pasien (PPOK & non-PPOK)
- satu text file (.txt) berisi penjelasan penamaan pada file audio



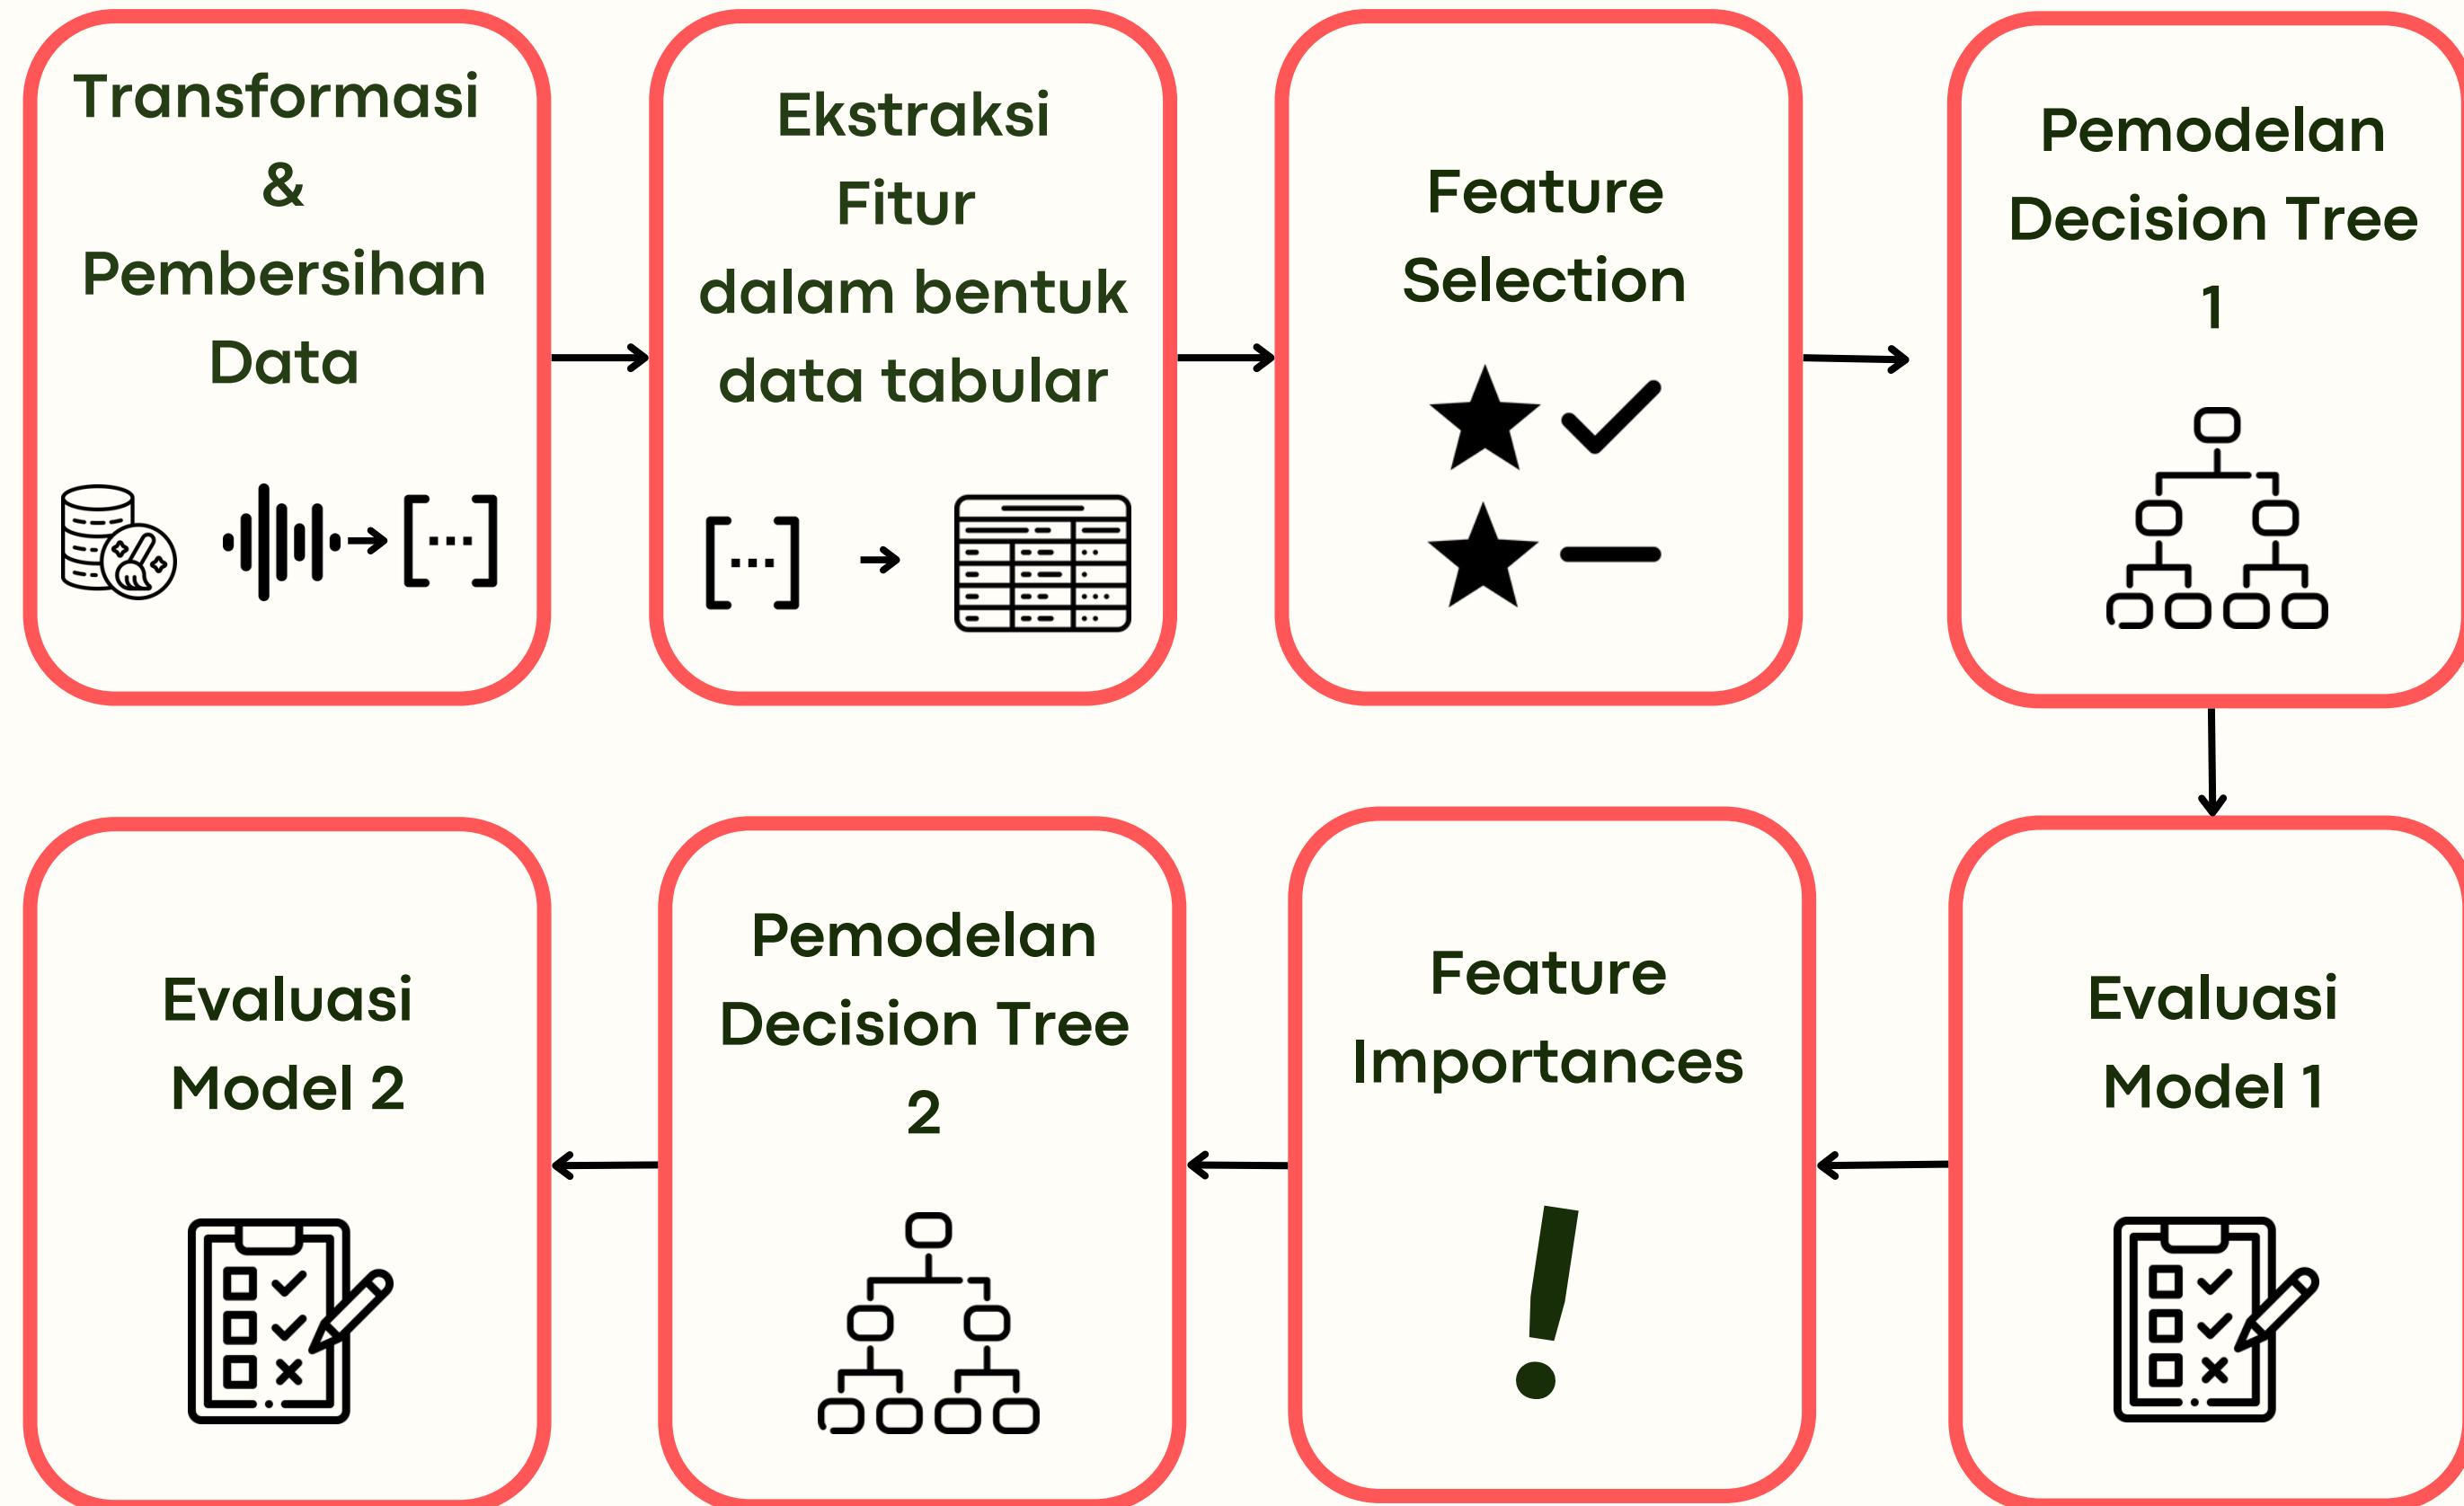
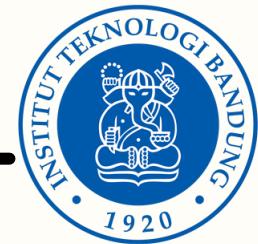
t_start	t_end	Crackles	Wheezes
9.279	11.15	0	0
11.15	13.036	0	0
13.036	14.721	0	0
14.721	16.707	0	0
16.707	18.507	0	0
18.507	19.964	0	0



101_1b1_AI_sc_Meditron.txt
101_1b1_AI_sc_Meditron.wav

METODOLOGI

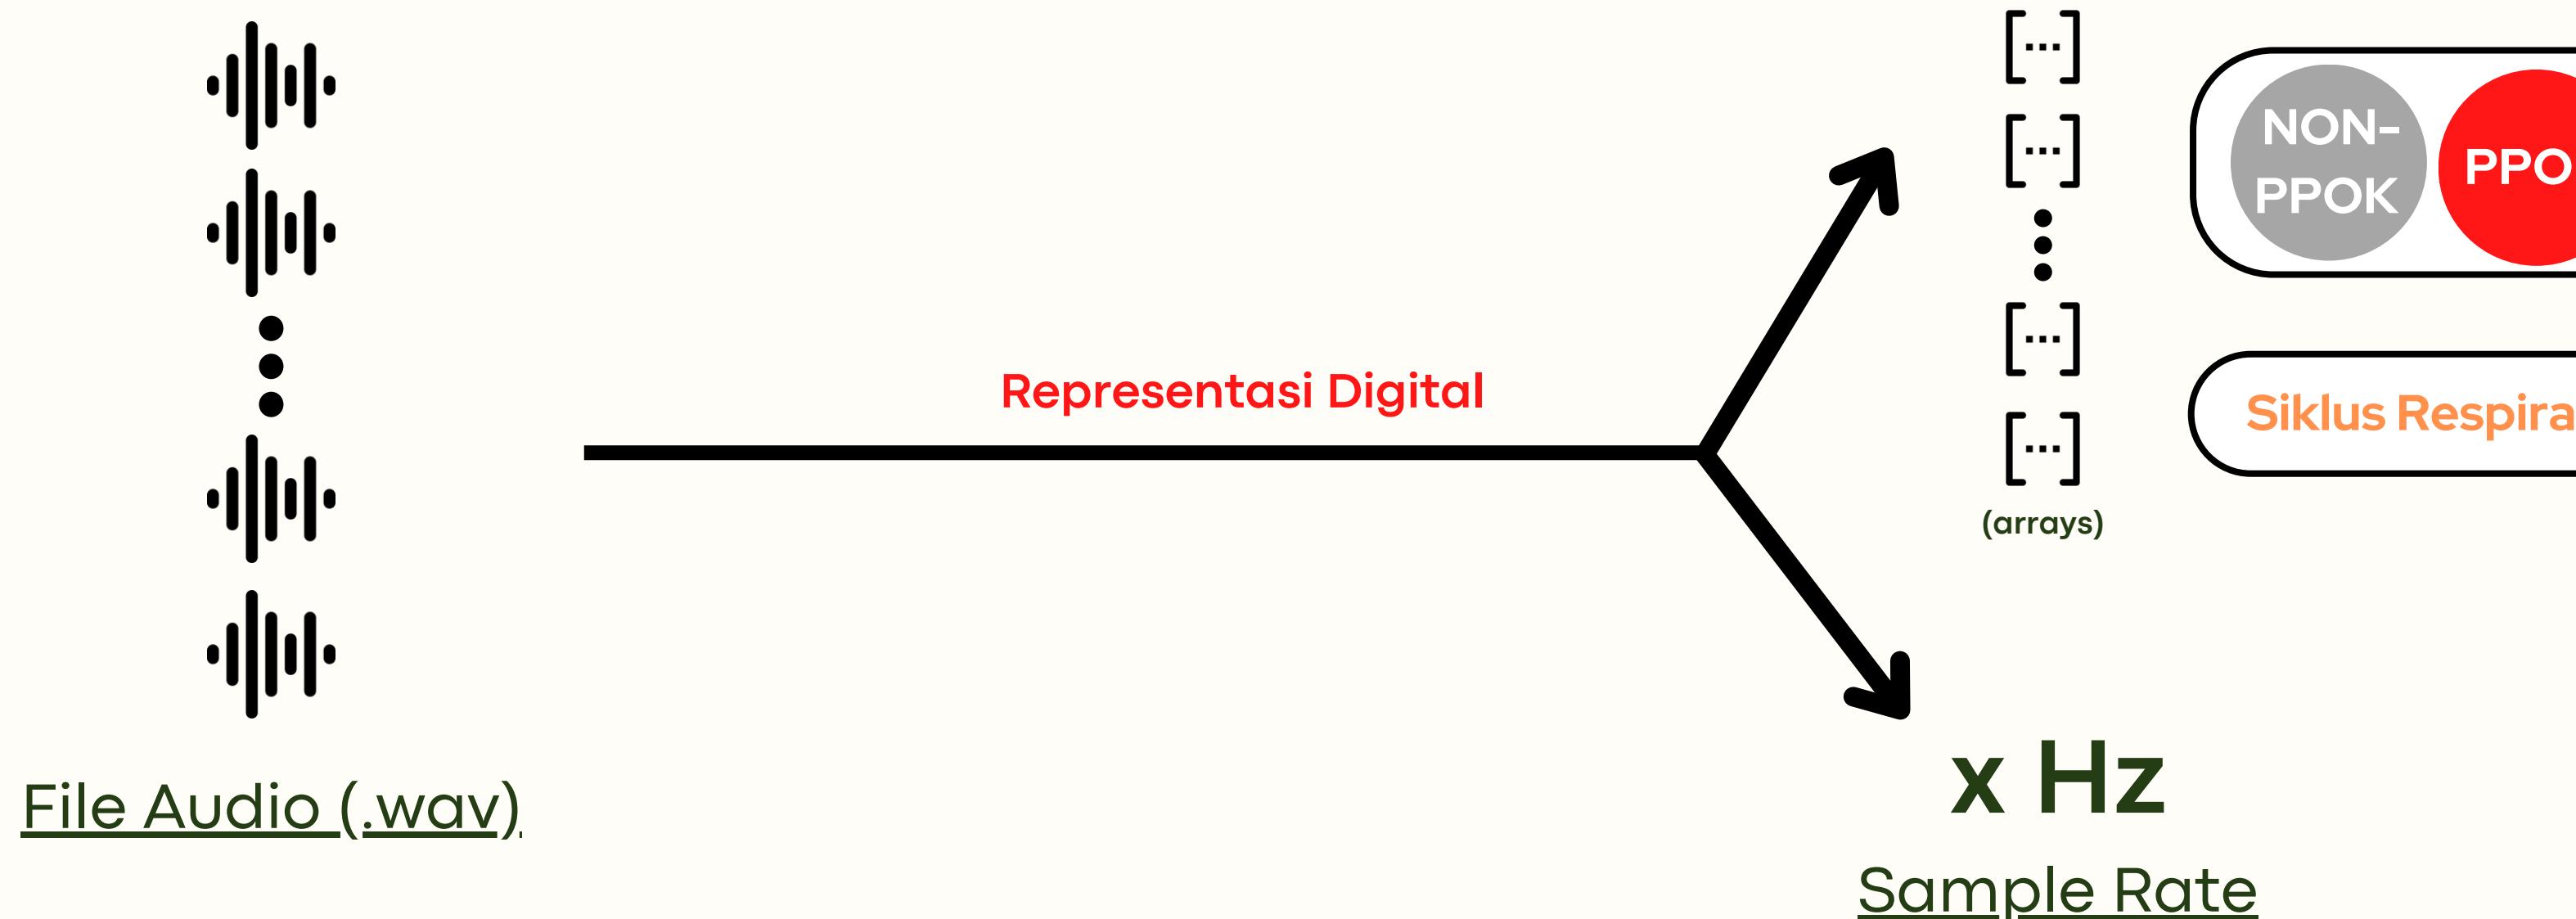
INSTITUT TEKNOLOGI BANDUNG



METODOLOGI

Transformasi & Pembersihan Data

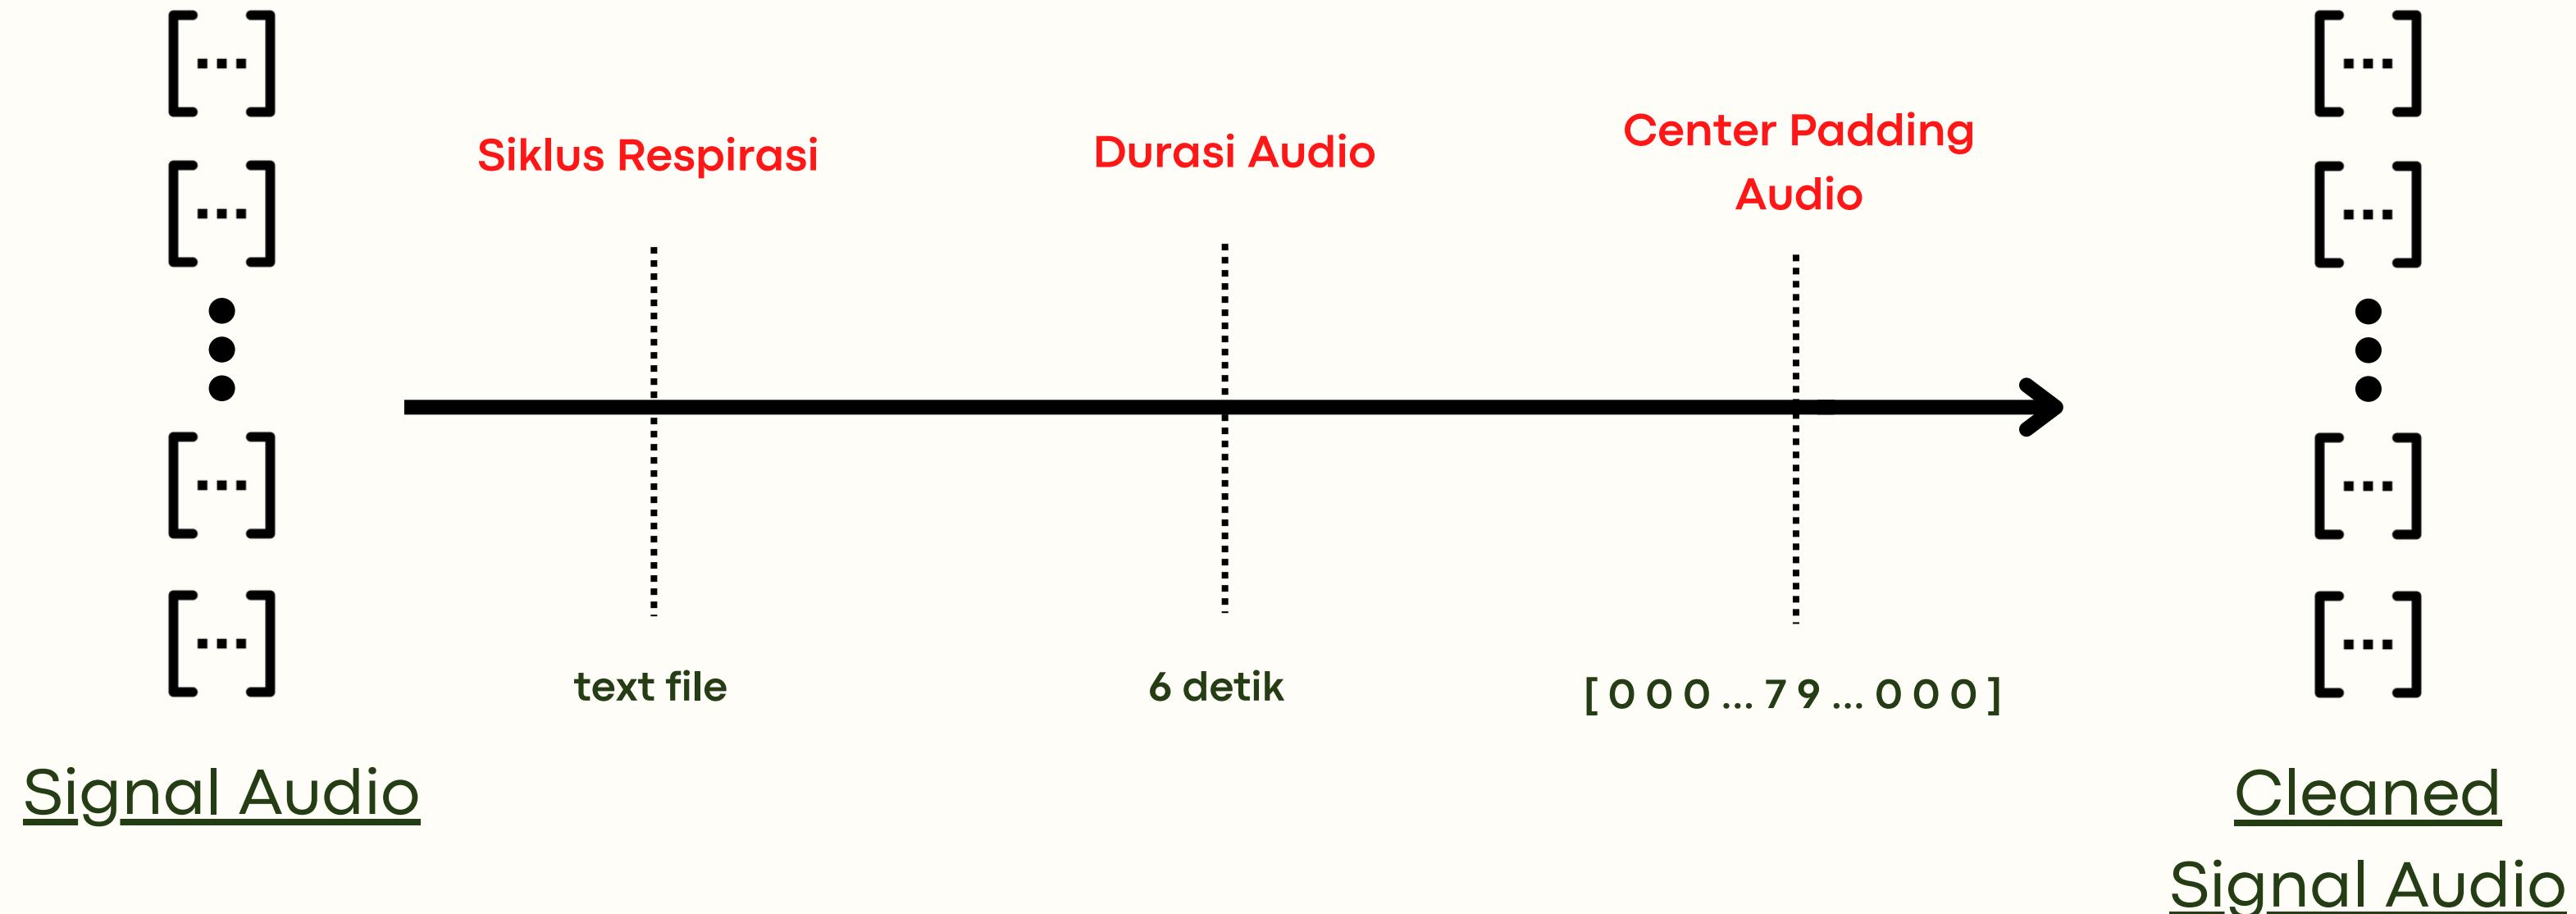
INSTITUT TEKNOLOGI BANDUNG



METODOLOGI

Transformasi & Pembersihan Data

INSTITUT TEKNOLOGI BANDUNG



METODOLOGI

Ekstraksi Fitur dalam Bentuk Data Tabular



INSTITUT TEKNOLOGI BANDUNG

The diagram illustrates the structure of an array as a vertical stack of rows. Each row is represented by a bracketed ellipsis (...). The rows are labeled from top to bottom: "... baris 1", "... baris 2", ":", "... baris n-1", and "... baris n". To the right of the stack, the text "aggregasi nilai-nilai array" is written, with a horizontal arrow pointing towards it. Below the stack, the text "Cleaned Signal Audio" is written.

[...]

[...]

:

[...]

[...]

... baris 1

... baris 2

:

... baris n-1

... baris n

baris 1

baris 2

baris n-1

baris n

aggregasi nilai-nilai array

Cleaned Signal Audio

METODOLOGI

Ekstraksi Fitur dalam Bentuk Data Tabular

INSTITUT TEKNOLOGI BANDUNG



Aggregasi Array / Fitur Data Tabular

mean	Rerata dari nilai-nilai pada array
median	Nilai median dari nilai-nilai pada array
max	Nilai maximum dari nilai-nilai pada array
min	Nilai minimum dari nilai-nilai pada array
std	Standar Deviasi dari nilai-nilai pada array
mean_non_pad	Rerata dari nilai-nilai pada array yang telah dibuang nilai paddingnya

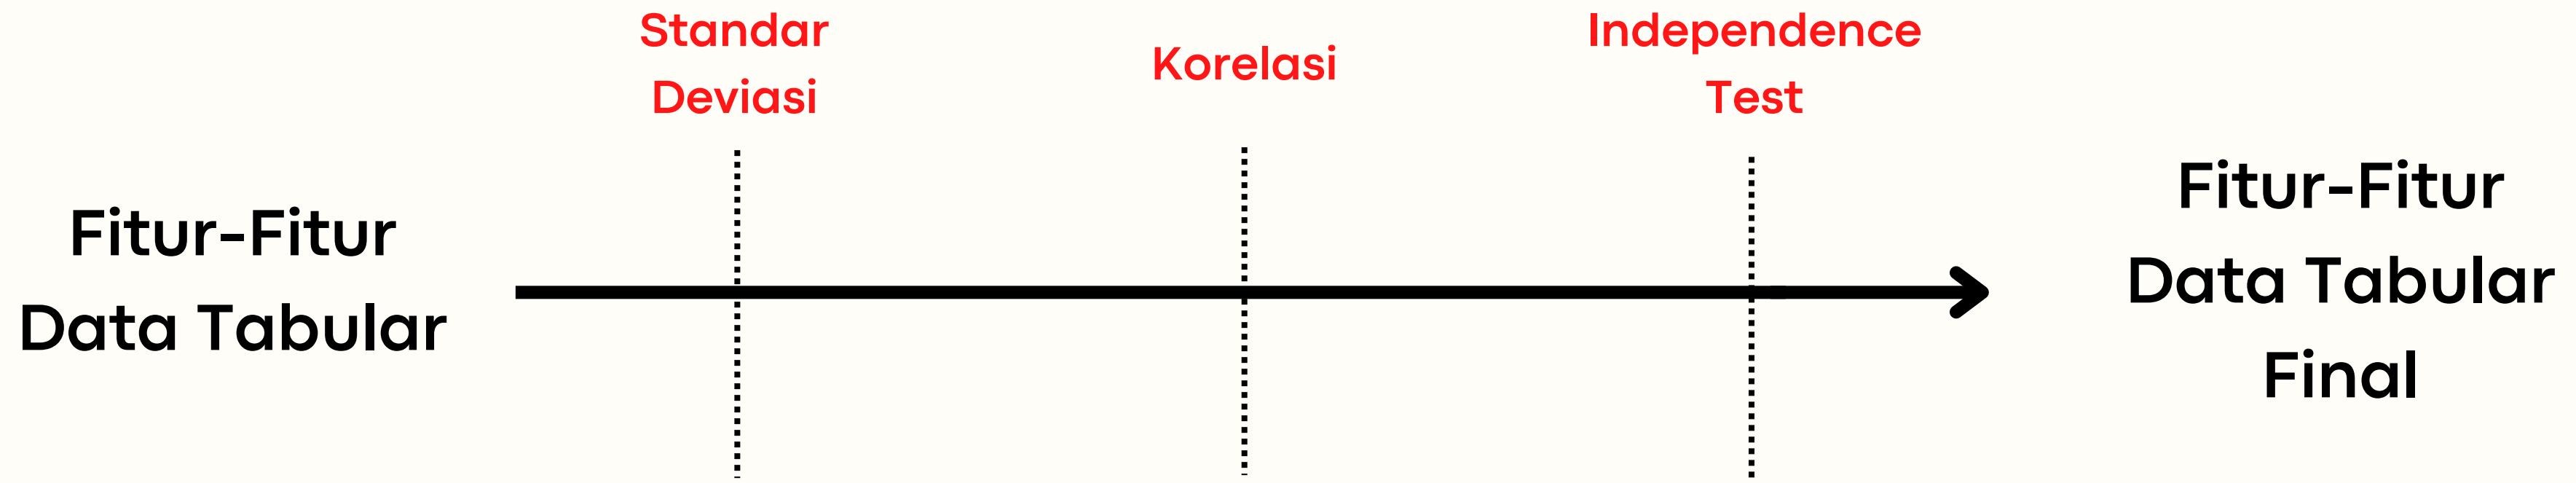
median_non_pad	Nilai median dari nilai-nilai pada array yang telah dibuang nilai paddingnya
max_non_pad	Nilai maximum dari nilai-nilai pada array yang telah dibuang nilai paddingnya
min_non_pad	Nilai minimum dari nilai-nilai pada array yang telah dibuang nilai paddingnya
std_non_pad	Standar Deviasi dari nilai-nilai pada array yang telah dibuang nilai paddingnya
non_zero	Jumlah nilai bukan nol pada array
zero	Jumlah nilai nol pada array

Data Tabular dari sumber data

crackles	Ada atau tidaknya suara menderak
weezels	Ada atau tidaknya suara mendecit
sex	Gender pada pasien
start	Waktu mulai dalam audio (dalam detik)
end	Waktu selesai dalam audio (dalam detik)

Feature Selection

INSTITUT TEKNOLOGI BANDUNG



Feature Selection

Standar Deviasi

INSTITUT TEKNOLOGI BANDUNG



start	9.87117
end	10.03274
crackles	0.47494
weezels	0.40137
sex	419.86067
mean	0.00022
median	0.00000
max	0.06986
min	0.02430
std	0.00563
mean_non_pad	0.00127
median_non_pad	0.00225
max_non_pad	0.06986
min_non_pad	0.02430
std_non_pad	0.01075
non_zero	9852.49433
zero	9852.49433

$$S = \sqrt{\frac{\sum(x_i - \bar{x})^2}{n - 1}}$$

Membuang fitur yang memiliki standar deviasi = 0

Feature Selection

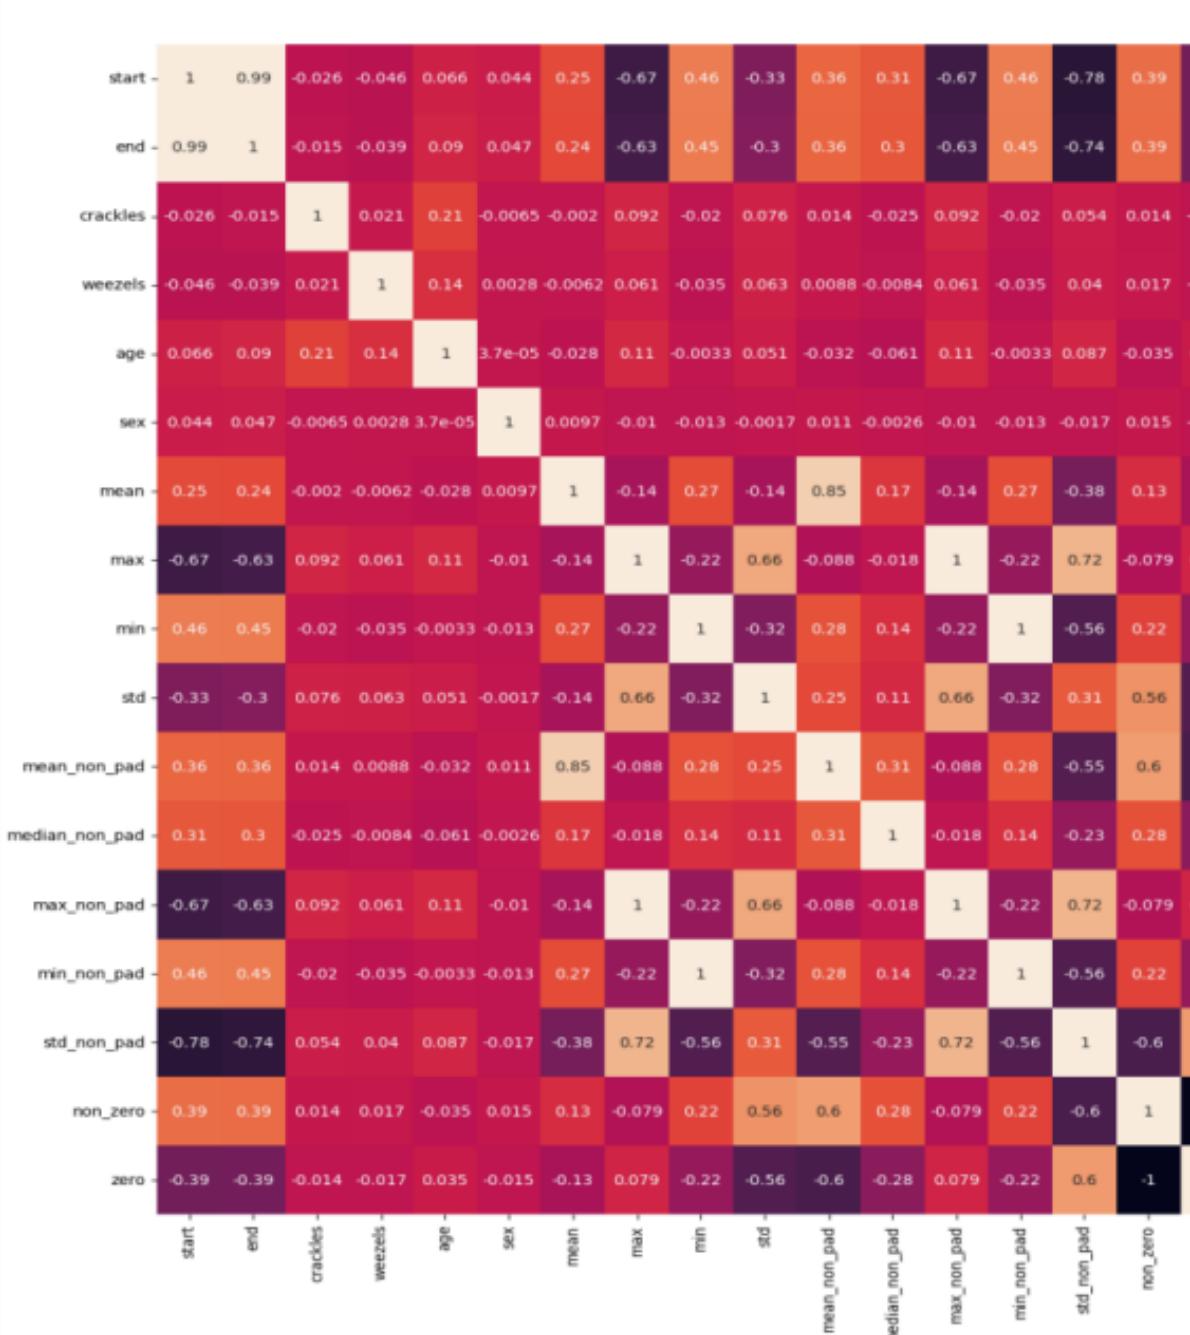
Korelasi

INSTITUT TEKNOLOGI BANDUNG

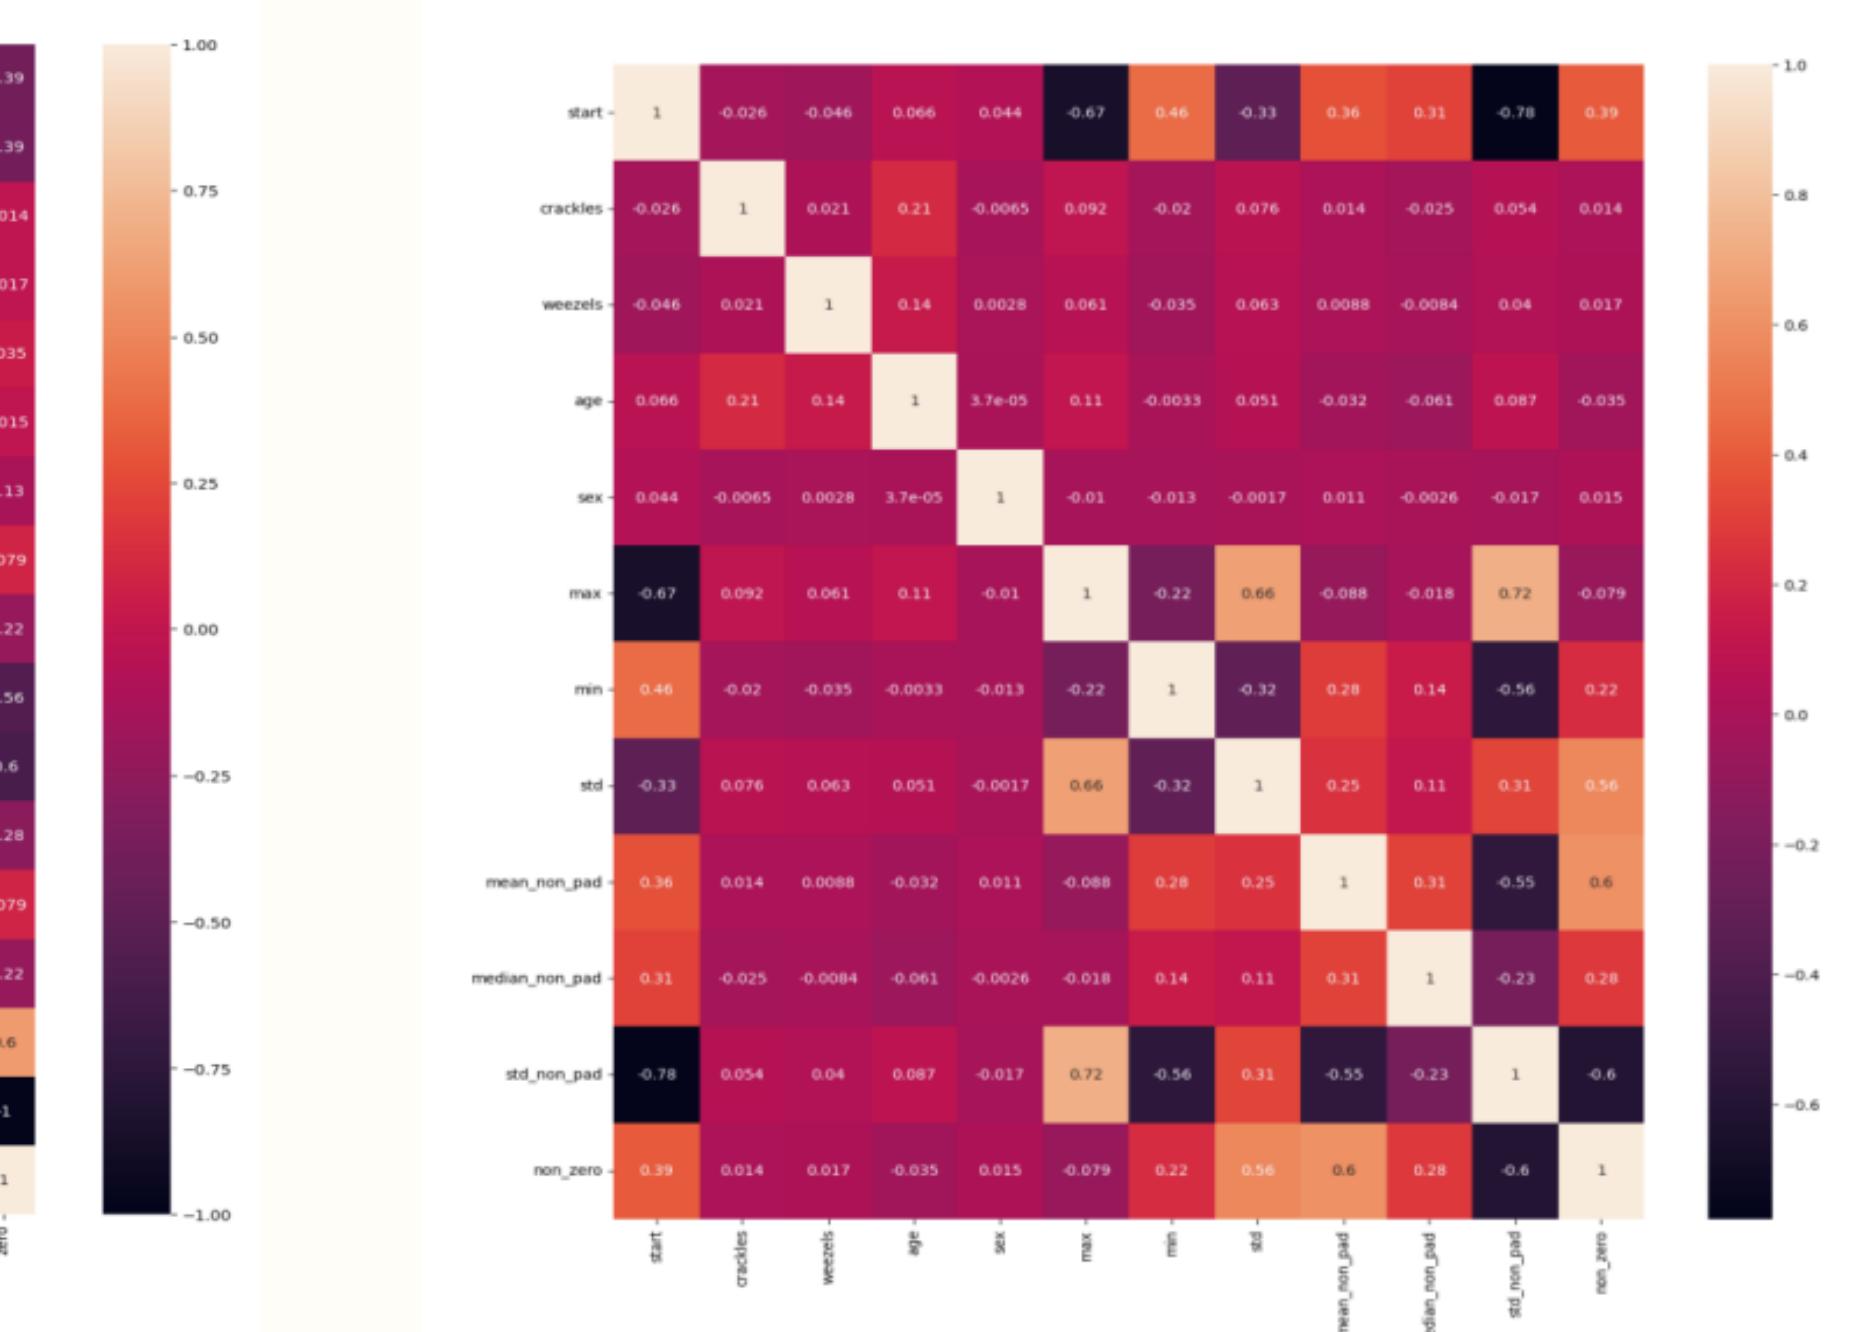


Korelasi Pearson

Sebelum



Sesudah



Membuang fitur yang memiliki nilai korelasi > 0.85 atau < -0.85

Feature Selection

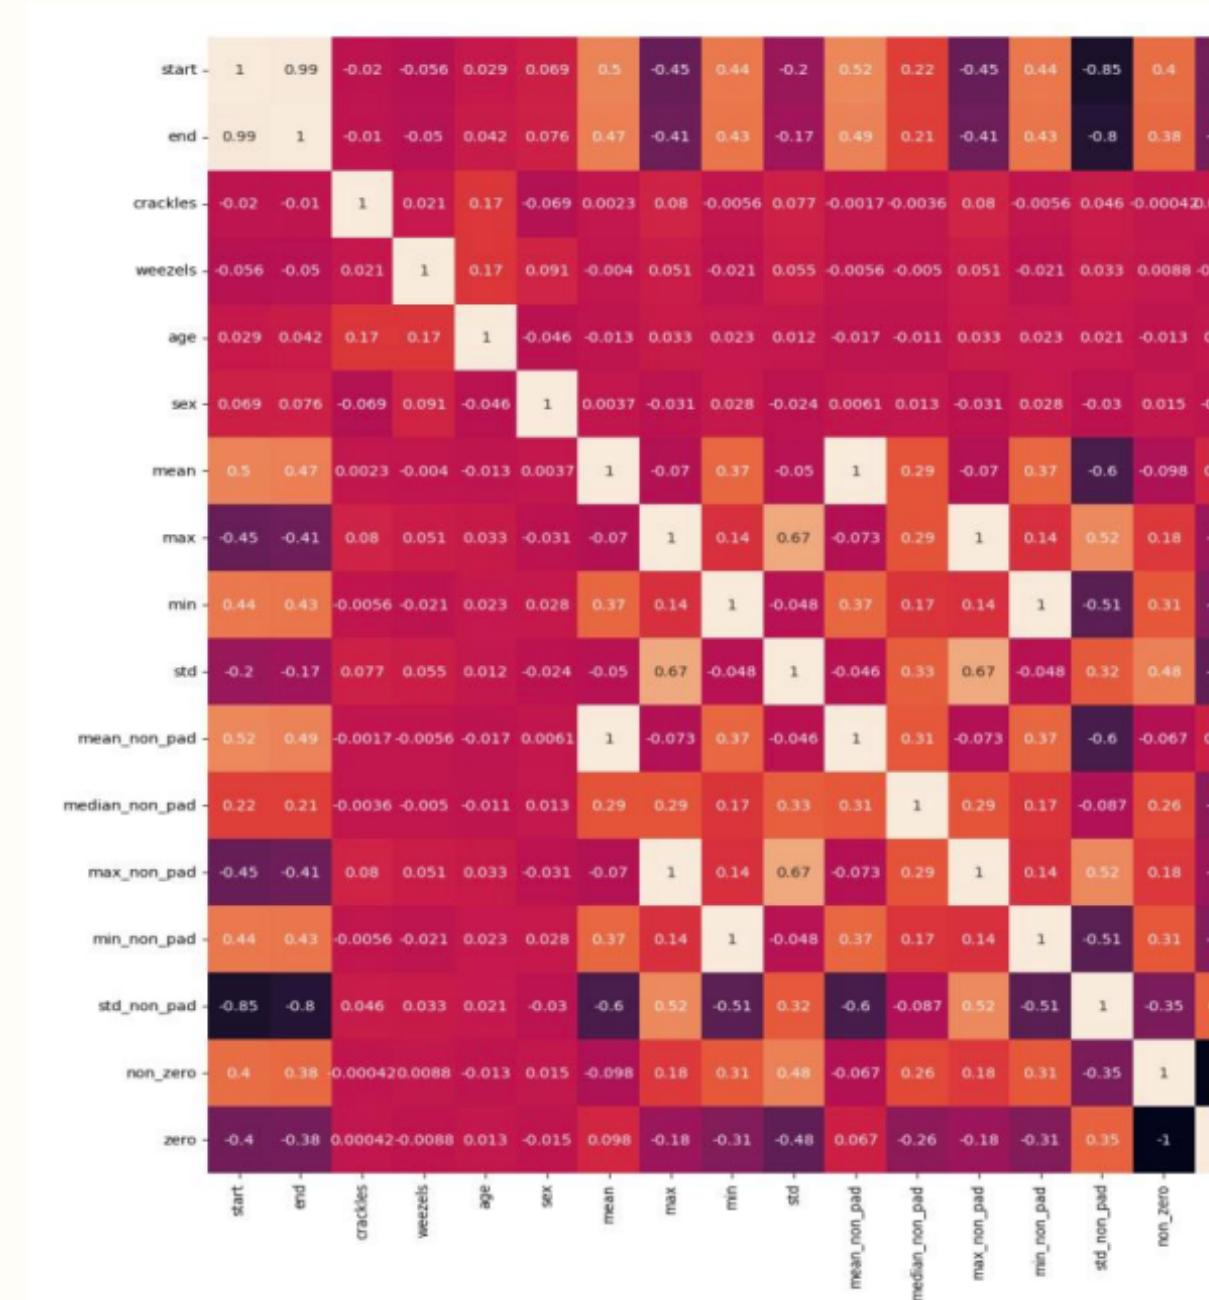
INSTITUT TEKNOLOGI BANDUNG



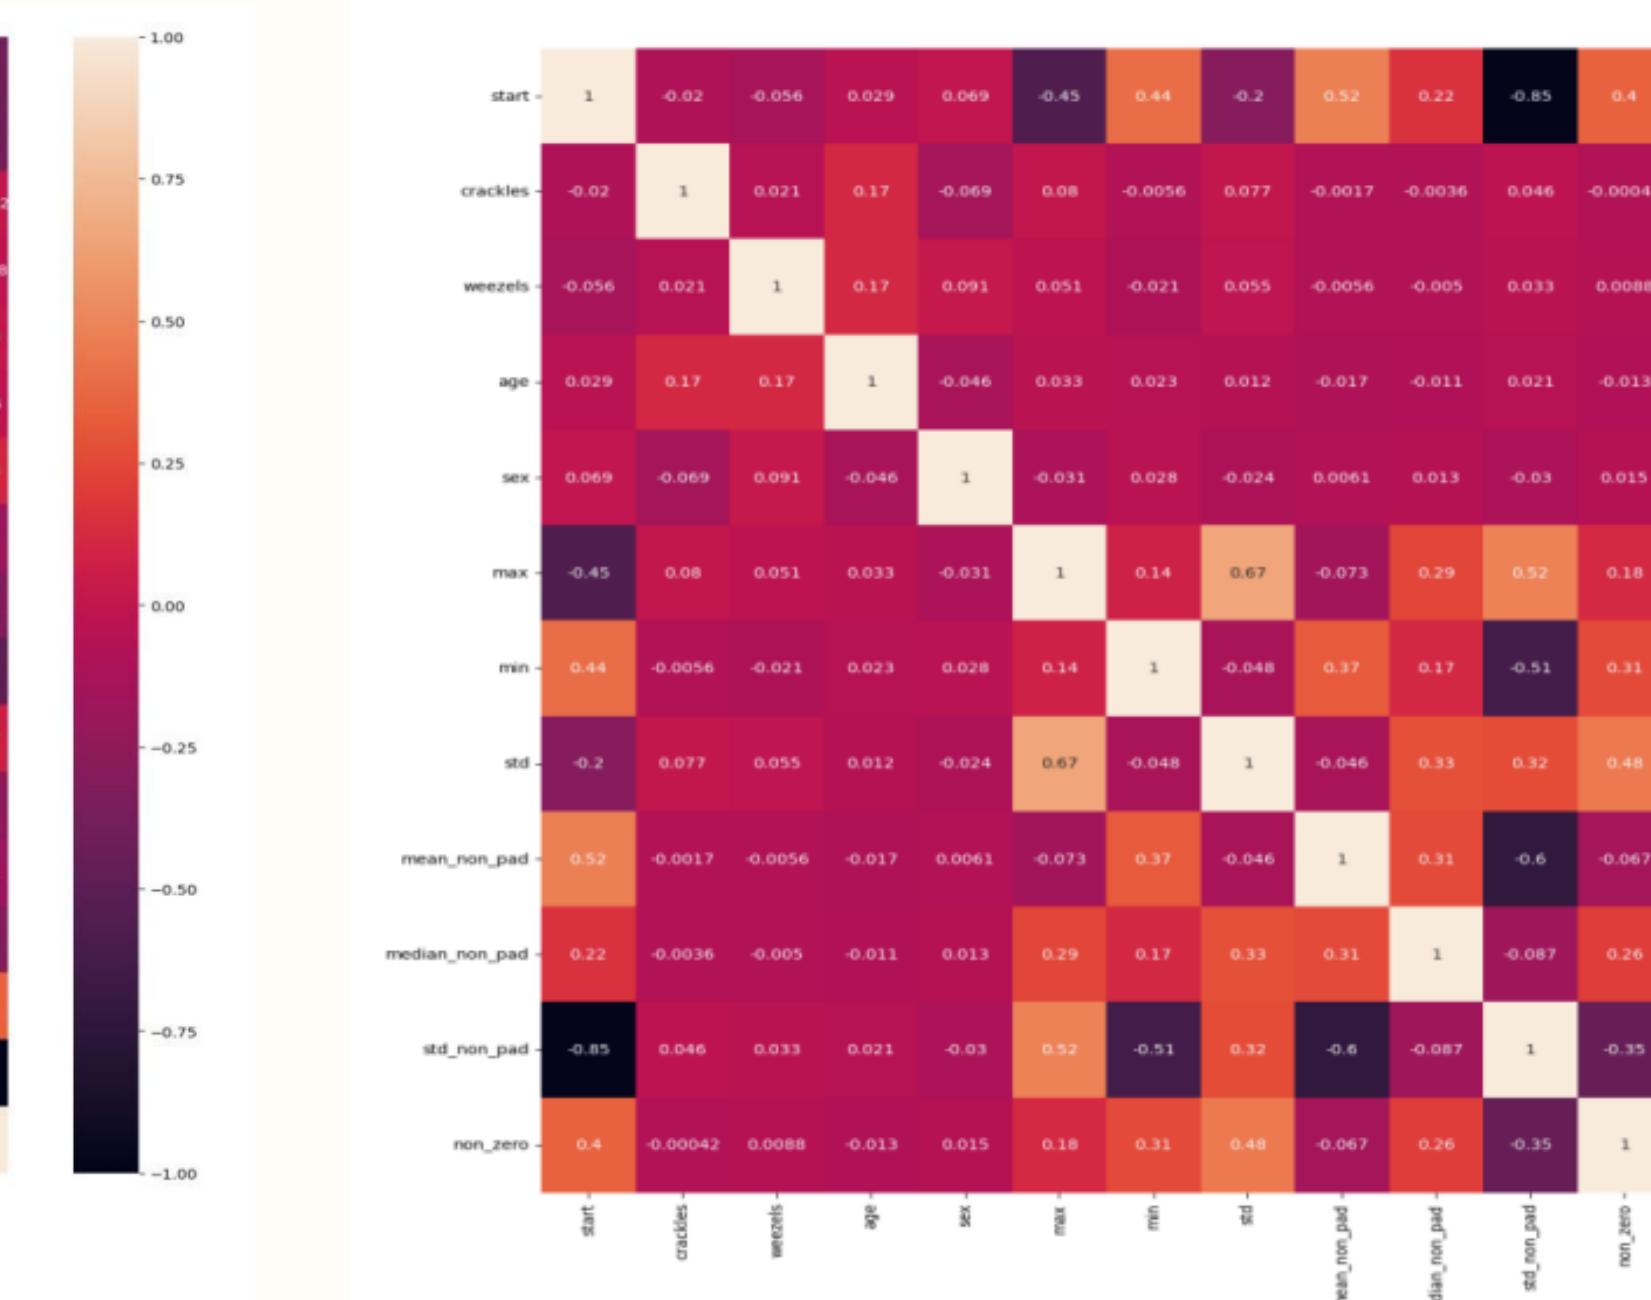
Korelasi

Korelasi Spearman

Sebelum



Sesudah



Membuang fitur yang memiliki nilai korelasi > 0.85 atau < -0.85

Feature Selection

Independence Test

INSTITUT TEKNOLOGI BANDUNG



Dilakukan antara **1 fitur dengan target variabel (PPOK / non-PPOK)**

Chi Squared Test

Fitur-fitur Kategorikal

H_0 : Dua variabel kategori adalah independen

H_1 : Dua variabel kategori adalah dependen

ANOVA

Fitur-fitur Numerikal

H_0 : Tidak ada perbedaan rata-rata antara level

H_1 : Terdapat perbedaan rata-rata antara level.

Pilih fitur yang memiliki p-value $\leq \alpha$ (0.05) [tolak H_0]

Feature Selection

INSTITUT TEKNOLOGI BANDUNG



Independence Test

Hasil Independence Test:

	fstat	pvalue	alpha	chosen
crackles	263.596626	2.822006e-59	0.05	True
weezels	35.122879	3.095426e-09	0.05	True
sex	54211.628234	0.000000e+00	0.05	True

Hasil Chi Squared Test (fitur kategorikal)

	fstat	pvalue	alpha	chosen
start	42.831756	6.393659e-11	0.05	True
max	50.568030	1.266868e-12	0.05	True
min	0.383049	5.359967e-01	0.05	False
std	13.740032	2.115774e-04	0.05	True
mean_non_pad	6.944969	8.424339e-03	0.05	True
median_non_pad	15.618419	7.826999e-05	0.05	True
std_non_pad	45.933775	1.324324e-11	0.05	True
non_zero	8.343187	3.883416e-03	0.05	True

Hasil ANOVA (fitur numerikal)

Membuang fitur dengan chosen = False

Feature Selection

Fitur untuk Pemodelan 2

INSTITUT TEKNOLOGI BANDUNG



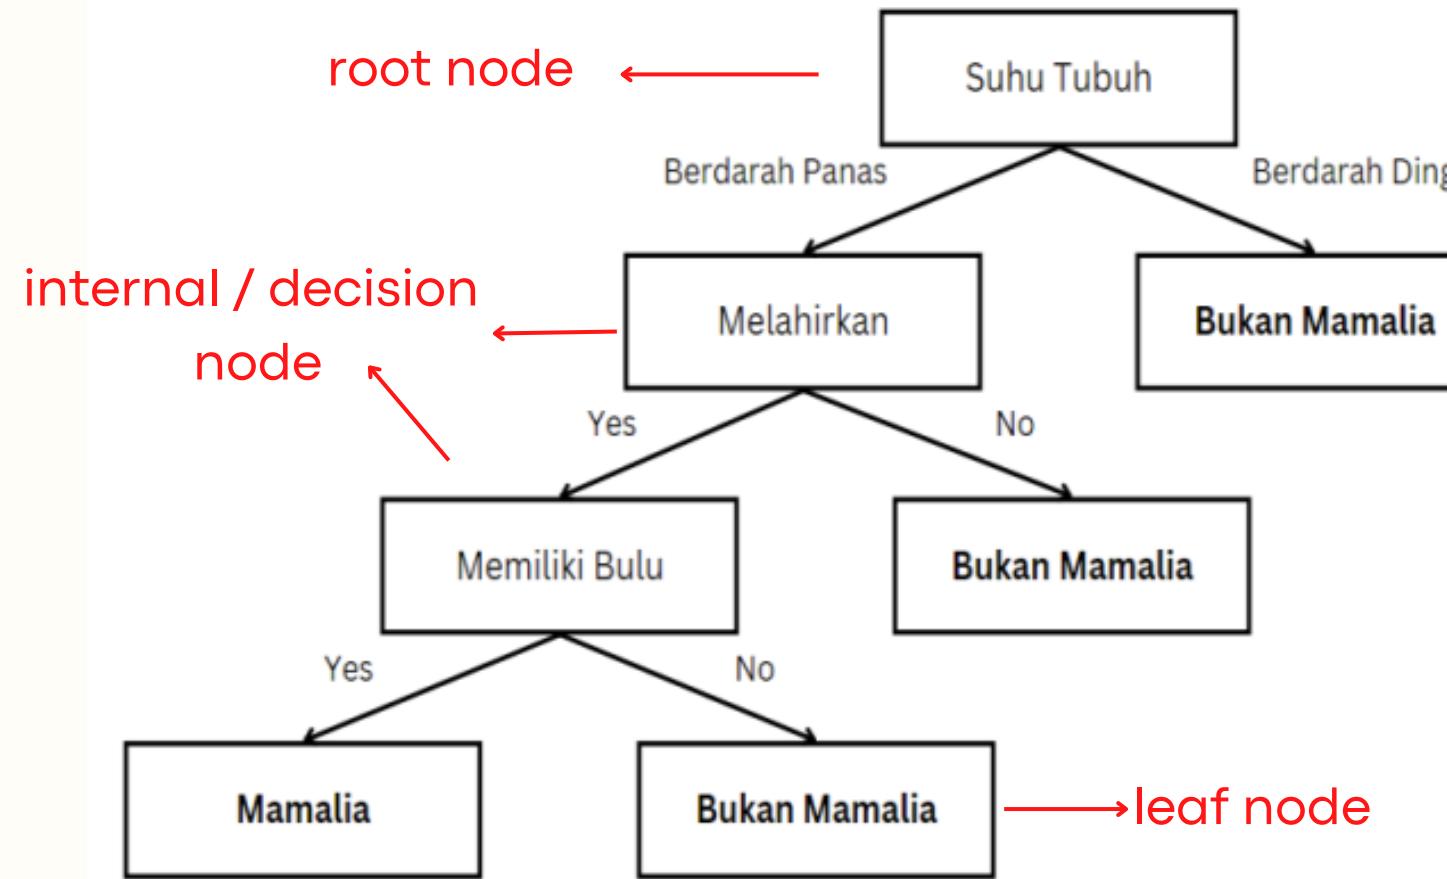
10 Fitur yang digunakan untuk pemodelan 1

crackles	Ada atau tidaknya suara menderak	max	Nilai maximum dari nilai-nilai pada array
weezels	Ada atau tidaknya suara mendecit	std_non_pad	Standar Deviasi dari nilai-nilai pada array yang telah dibuang nilai paddingnya
sex	Gender pada pasien	start	Waktu mulai dalam audio (dalam detik)
std	Standar Deviasi dari nilai-nilai pada array	median_non_pad	Nilai median dari nilai-nilai pada array yang telah dibuang nilai paddingnya
mean_non_pad	Rerata dari nilai-nilai pada array yang telah dibuang nilai paddingnya	non_zero	Jumlah nilai bukan nol pada array

PEMODELAN

Decision Tree

INSTITUT TEKNOLOGI BANDUNG



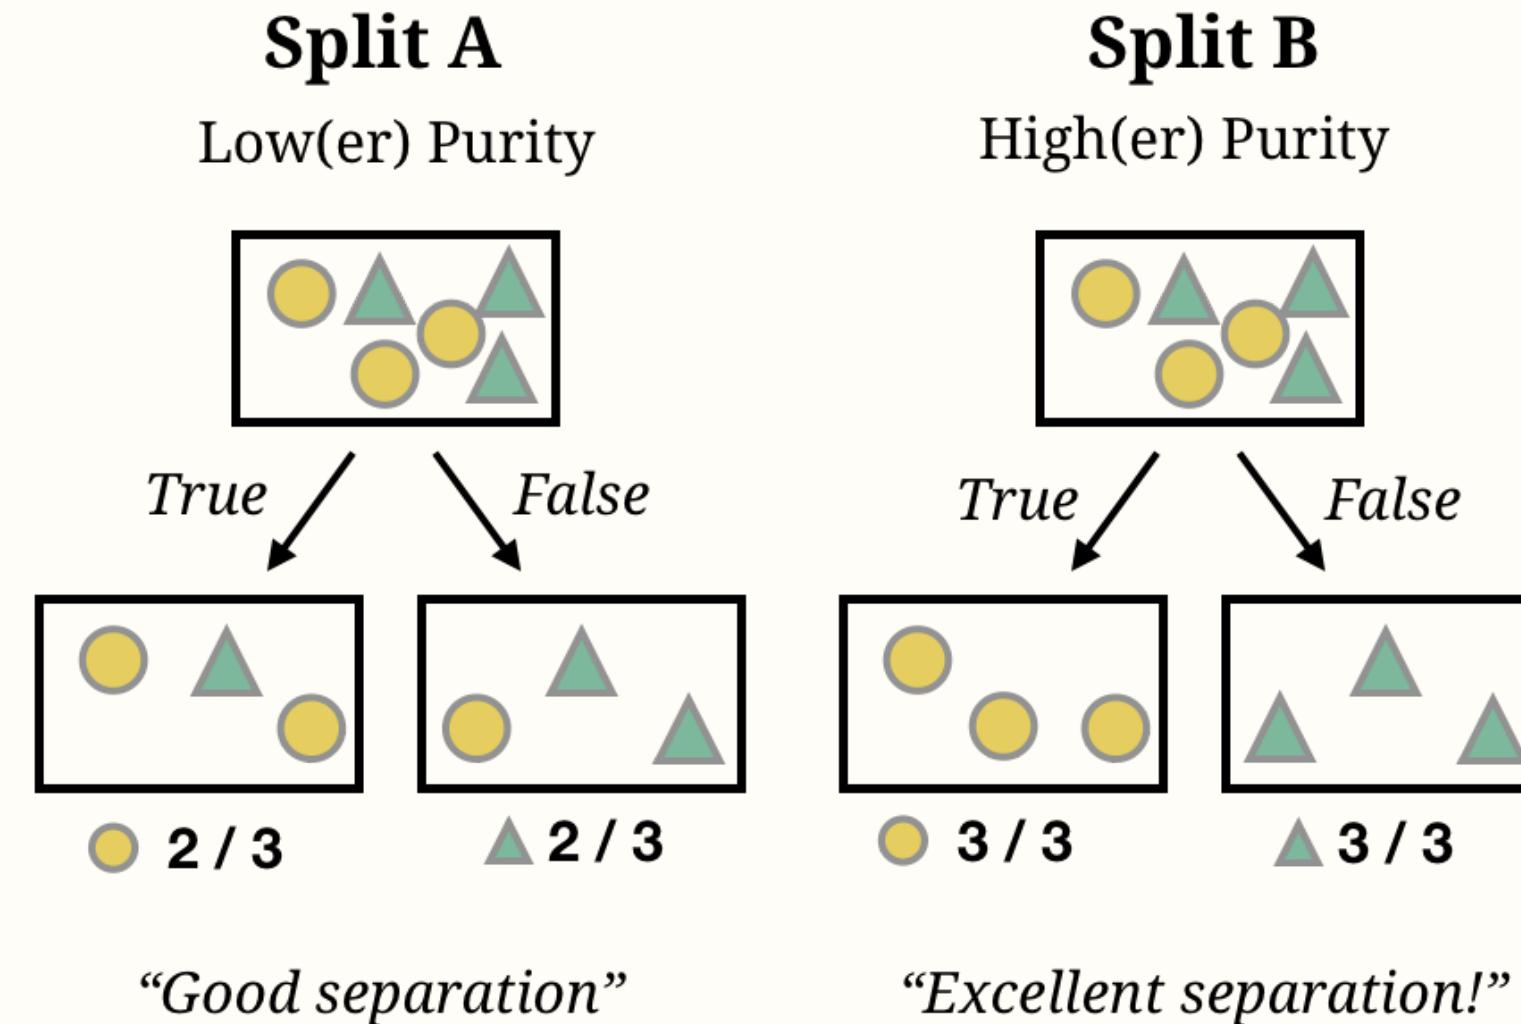
- Salah satu jenis metode **Supervised Learning** yang digunakan dalam machine learning.
- Terdiri dari **node** dan **branches**
- Secara umum decision tree **mengambil pernyataan atau hipotesis atau kondisi**, kemudian membuat **keputusan apakah kondisi tersebut berlaku atau tidak**.
- Konsep utama metode Decision Tree **melibatkan pembuatan aturan yang terstruktur**, untuk melakukan **pemisahan/ splitting berdasarkan variabel independen (fitur)**.
- Hasil splitting ini yang kemudian membentuk **pohon bercabang**.

PEMODELAN

Decision Tree

- Node purity: kondisi kemurnian sebuah node.
- Terkadang sebuah node keputusan tidaklah murni, atau campuran dari kedua kelas variabel dependen.
- Node murni: node yang memiliki satu kelas.
- Tujuan dalam metode ini adalah melakukan splitting dengan meminimalkan impurity dari variabel dependen (output).
- Tujuan ini dapat dicapai dengan cara mempartisi observasi menggunakan variabel independen sehingga pada akhirnya menghasilkan observasi variabel dependen murni yang hanya dimiliki oleh satu kelas

INSTITUT TEKNOLOGI BANDUNG



PEMODELAN

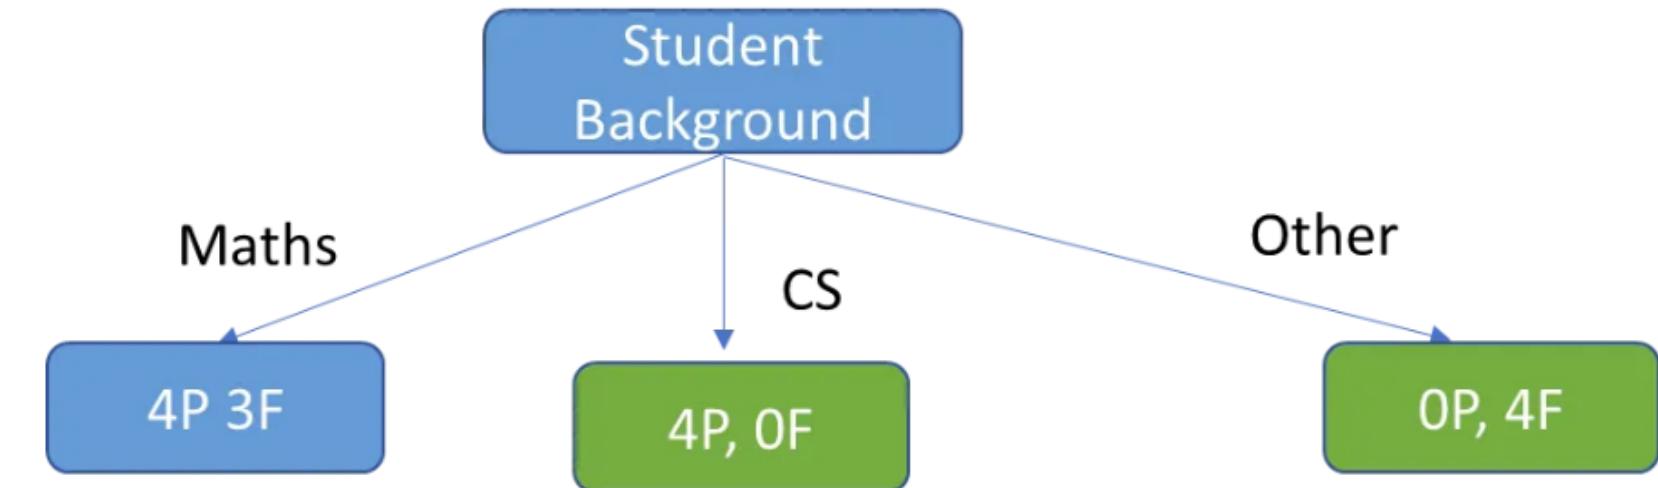
Decision Tree

- **Gini Index (Gini impurity)**: ukuran probabilitas untuk contoh acak yang **salah diklasifikasikan** ketika dipilih secara acak
- nilai maksimum Gini Index adalah 0.5
- Semakin kecil nilai gini index, semakin kecil kemungkinan untuk misklasifikasi.

$$Gini = 1 - \sum_{i=1}^j P(i)^2$$

- j adalah jumlah kelas yang ada
 - di kasus ini j = 2, yaitu Pass dan Fail
- P(i) : probabilitas kelas ke-i di node.

INSTITUT TEKNOLOGI BANDUNG



$$Gini_{maths} = 1 - \left(\frac{4}{7}\right)^2 - \left(\frac{3}{7}\right)^2 = .4897$$

$$Gini_{CS} = 1 - \left(\frac{4}{4}\right)^2 - \left(\frac{0}{5}\right)^2 = 0$$

$$Gini_{others} = 1 - \left(\frac{0}{4}\right)^2 - \left(\frac{4}{4}\right)^2 = 0$$

PEMODELAN 1

INSTITUT TEKNOLOGI BANDUNG



Decision Tree

- Berikut Parameter yang digunakan dalam model Decision Tree 1

Parameter	Nilai
Criterion	<i>Gini</i>
Max depth	30
Min Sample Split	2
Min Sample Leaf	1
Max Features	8
Min Impurity Decrease	0
Max Leaf Node	<i>none</i> (<u>tidak terbatas pada jumlah maksimum</u>)
Cost Complexity Pruning	0.005

- Criterion : metode saat melakukan pemisahan / splitting
- Max Depth: kedalaman maksimum pohon. [Sampai Daun kondisi Pure]
- Min Sample Split : jumlah minimum sampel yang harus dimiliki node internal sebelum dapat dibagi, untuk mencegah pertumbuhan pohon.[2]
- Min Sample Leaf: jumlah minimum sampel yang harus dimiliki oleh daun. [1]
- Max Features: jumlah fitur yang perlu dipertimbangkan saat dilakukan pemisahan / splitting, mulai dari root node sampai dengan terminal node.
- Min impurity Decrease: Nilai minimum dari penurunan impurity untuk menjadi syarat splitting. [0]
- Max Leaf Node: jumlah maksimum daun pada pohon. [none]
- Cost Complexity Pruning: mengontrol ukuran pohon. Semakin tinggi nilai parameter ini, maka jumlah node yang dipangkas akan semakin besar. [0]

EVALUASI MODEL 1

INSTITUT TEKNOLOGI BANDUNG



Berikut adalah hasil prediksi model pada data Train dan Test, dengan proporsi PPOK dan non-PPOK sebesar 60:40.

Evaluasi model pada data train

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	70%	93%	80%	72%
Tidak memiliki PPOK (non-PPOK)	79%	41%	54%	

Evaluasi model pada data test

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	71%	90%	79%	72%
Tidak memiliki PPOK (non-PPOK)	75%	45%	56%	

Hasil menunjukkan bahwa model decision tree **tidak overfitting**.

$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

$$F1 Score = 2 \times \frac{\text{recall} \times \text{precision}}{\text{recall} + \text{precision}}$$

FEATURE IMPORTANCES

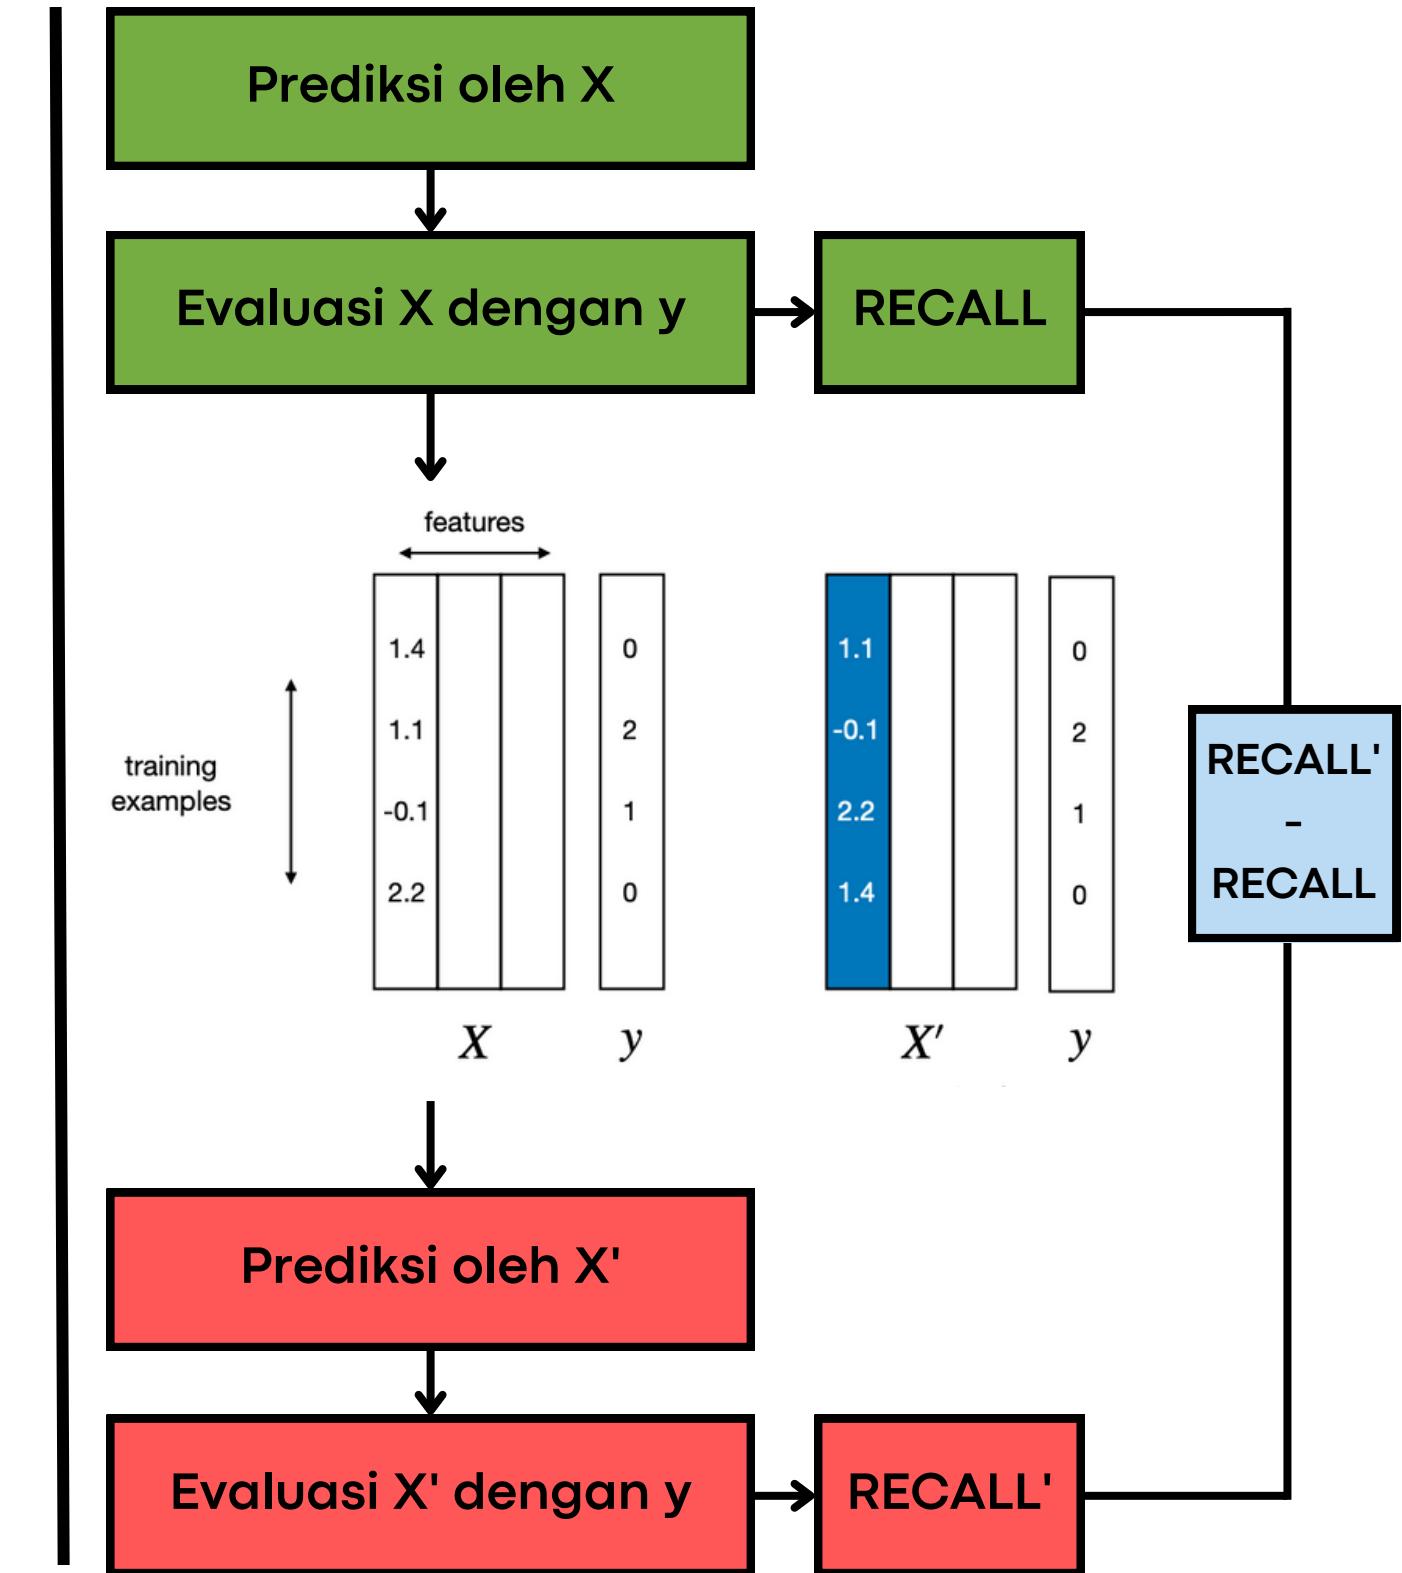
INSTITUT TEKNOLOGI BANDUNG



Permutation Feature Importances adalah suatu metode untuk menentukan tingkat kepentingan fitur.

Untuk setiap fitur (variabel independen / kolom) yang ada lakukan :

1. Shuffle nilai fitur secara acak sambil mempertahankan nilai fitur lainnya tetap konstan.
2. Hasilkan prediksi baru berdasarkan nilai yang diacak dan lakukan evaluasi prediksi baru tersebut.
3. Hitung skor feature importance dengan menghitung penurunan kualitas prediksi baru relatif terhadap prediksi awal.
4. Setelah menghitung skor feature importance untuk semua fitur, lakukan pemeringkatan dalam hal kegunaan prediktif.

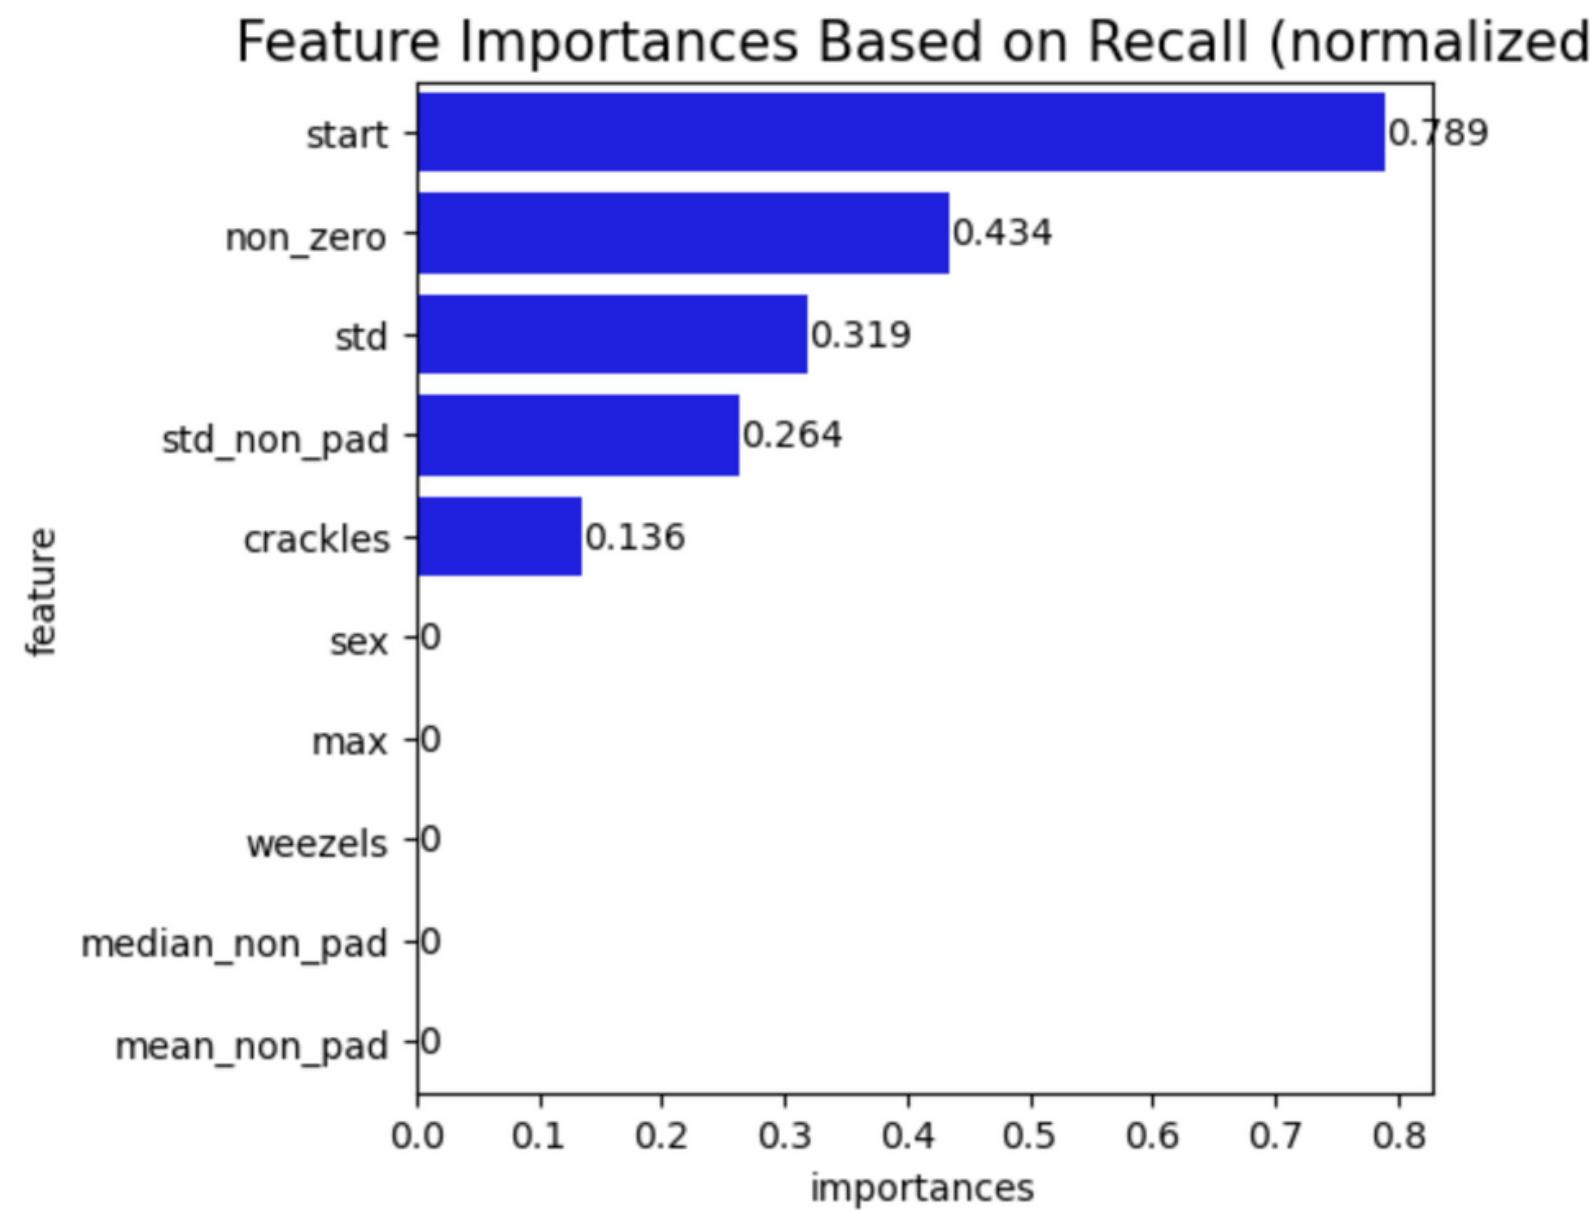


FEATURE IMPORTANCES

INSTITUT TEKNOLOGI BANDUNG



Dengan menggunakan permutation feature importances, dengan metrik evaluasi **recall** pada kelas memiliki PPOK, didapatkan hasil sebagai berikut:



- Didapatkan bahwa **5 fitur yang paling berperan penting** dalam menentukan seseorang memiliki PPOK, yaitu variabel independen **start, non_zero, std, std_non_pad, dan crackles**.
- Selain 5 fitur ini, **5 fitur lainnya memiliki nilai importances 0**, atau dengan kata lain **tidak memiliki dampak pada model yang dipakai**, maka dengan itu **5 fitur lainnya ini akan dibuang**.

Feature Importances

Fitur untuk Pemodelan 2

INSTITUT TEKNOLOGI BANDUNG



5 Fitur yang digunakan untuk pemodelan 2

crackles	Ada atau tidaknya suara menderak
std_non_pad	Standar Deviasi dari nilai-nilai pada array yang telah dibuang nilai paddingnya
std	Standar Deviasi dari nilai-nilai pada array
start	Waktu mulai dalam audio (dalam detik)
non_zero	Jumlah nilai bukan nol pada array

PEMODELAN 2

INSTITUT TEKNOLOGI BANDUNG



Decision Tree

- Berikut Parameter yang digunakan dalam model Decision Tree 2

Parameter	Nilai
Criterion	<i>Gini</i>
Max depth	30
Min Sample Split	2
Min Sample Leaf	1
Max Features	8
Min Impurity Decrease	0
Max Leaf Node	<i>none</i> (<u>tidak terbatas pada jumlah maksimum</u>)
Cost Complexity Pruning	0.005

- Criterion : metode saat melakukan pemisahan / splitting
- Max Depth: kedalaman maksimum pohon. [Sampai Daun kondisi Pure]
- Min Sample Split : jumlah minimum sampel yang harus dimiliki node internal sebelum dapat dibagi, untuk mencegah pertumbuhan pohon.[2]
- Min Sample Leaf: jumlah minimum sampel yang harus dimiliki oleh daun. [1]
- Max Features: jumlah fitur yang perlu dipertimbangkan saat dilakukan pemisahan / splitting, mulai dari root node sampai dengan terminal node.
- Min impurity Decrease: Nilai minimum dari penurunan impurity untuk menjadi syarat splitting. [0]
- Max Leaf Node: jumlah maksimum daun pada pohon. [none]
- Cost Complexity Pruning: mengontrol ukuran pohon. Semakin tinggi nilai parameter ini, maka jumlah node yang dipangkas akan semakin besar. [0]

EVALUASI MODEL 2

INSTITUT TEKNOLOGI BANDUNG



Setelah Feature Importances

Berikut adalah hasil evaluasi model pada data **Train** dan **Test**, dengan proporsi PPOK dan non-PPOK sebesar **60:40**, setelah melakukan pembuang fitur **Feature Importances**, dan parameter yang sama dengan model sebelumnya.

Evaluasi model pada data train

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	70%	93%	80%	72%
Tidak memiliki PPOK (non-PPOK)	79%	41%	54%	

Evaluasi model pada data test

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	71%	90%	79%	72%
Tidak memiliki PPOK (non-PPOK)	75%	45%	56%	

Model decision tree 2 tidak overfitting dan memiliki hasil yang sama dengan model decision tree 1

$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

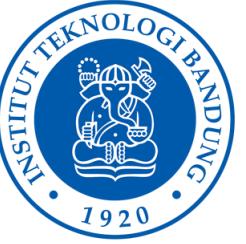
$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

$$F1 Score = 2 \times \frac{\text{recall} \times \text{precision}}{\text{recall} + \text{precision}}$$

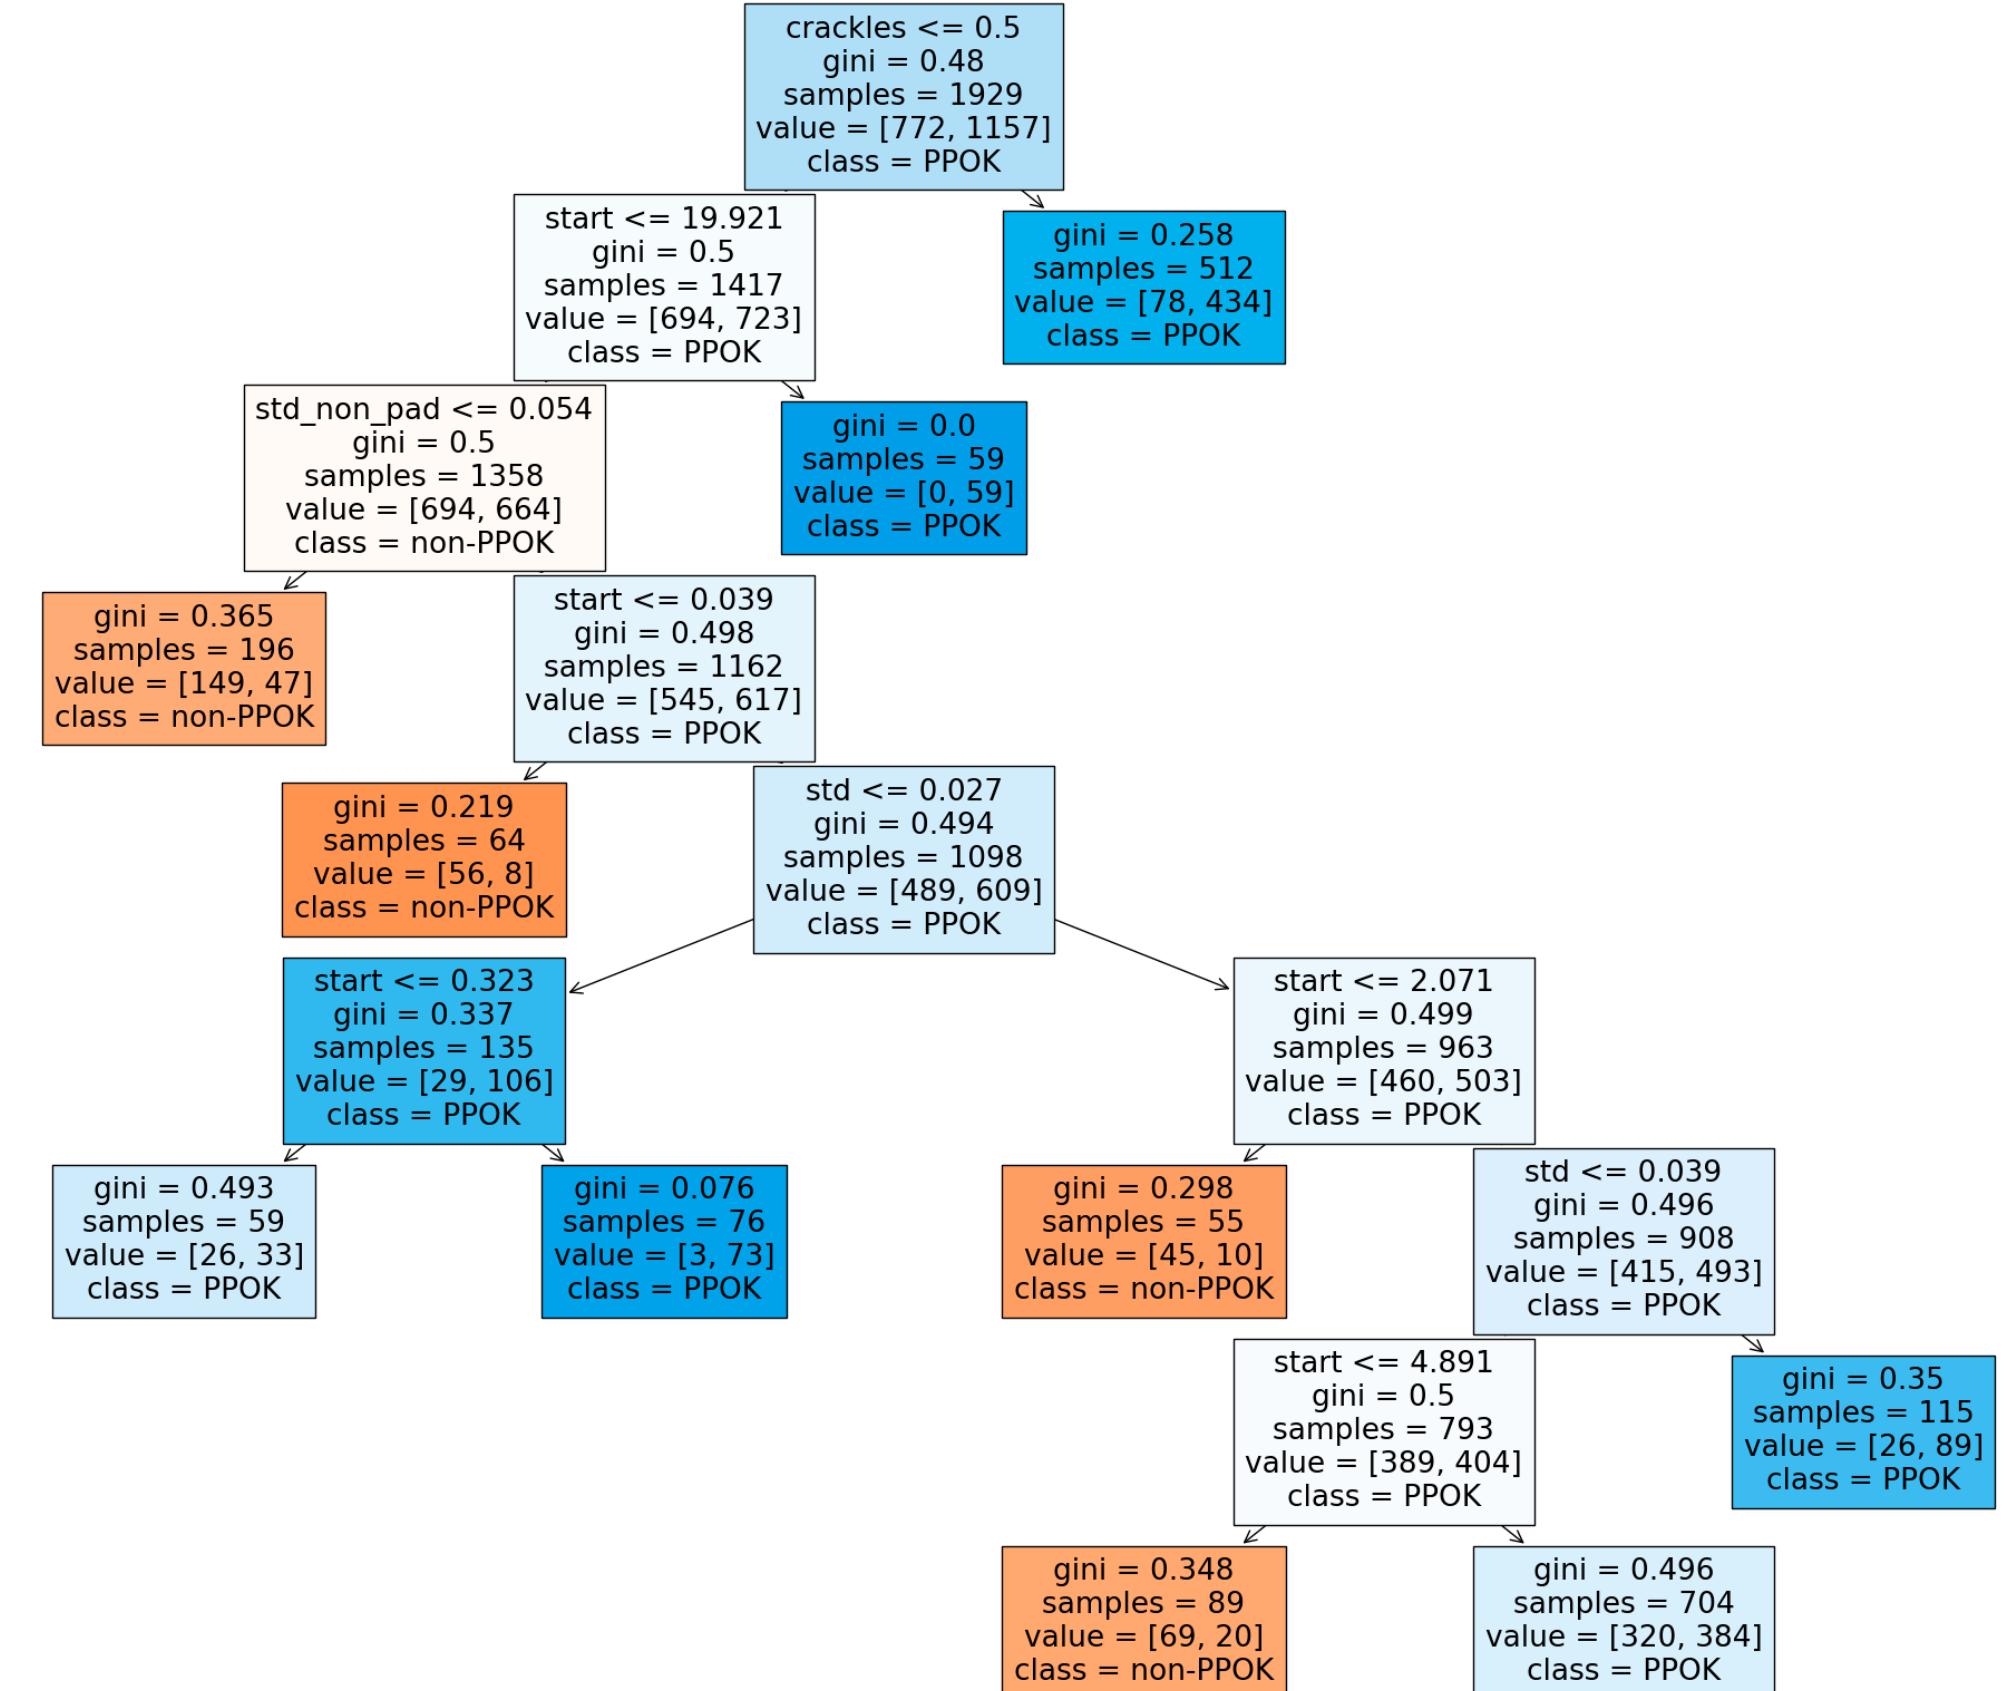
DECISION TREE PLOT

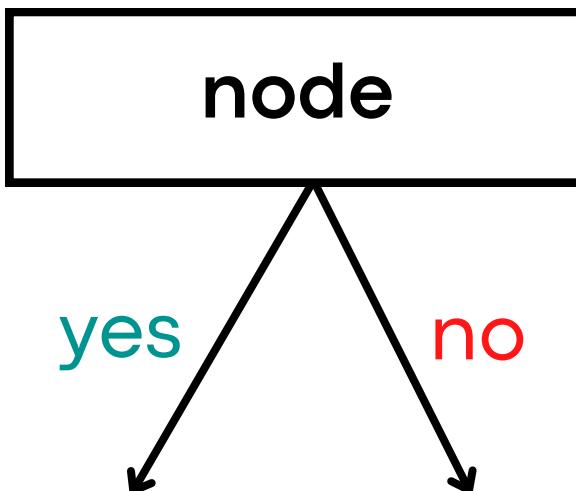
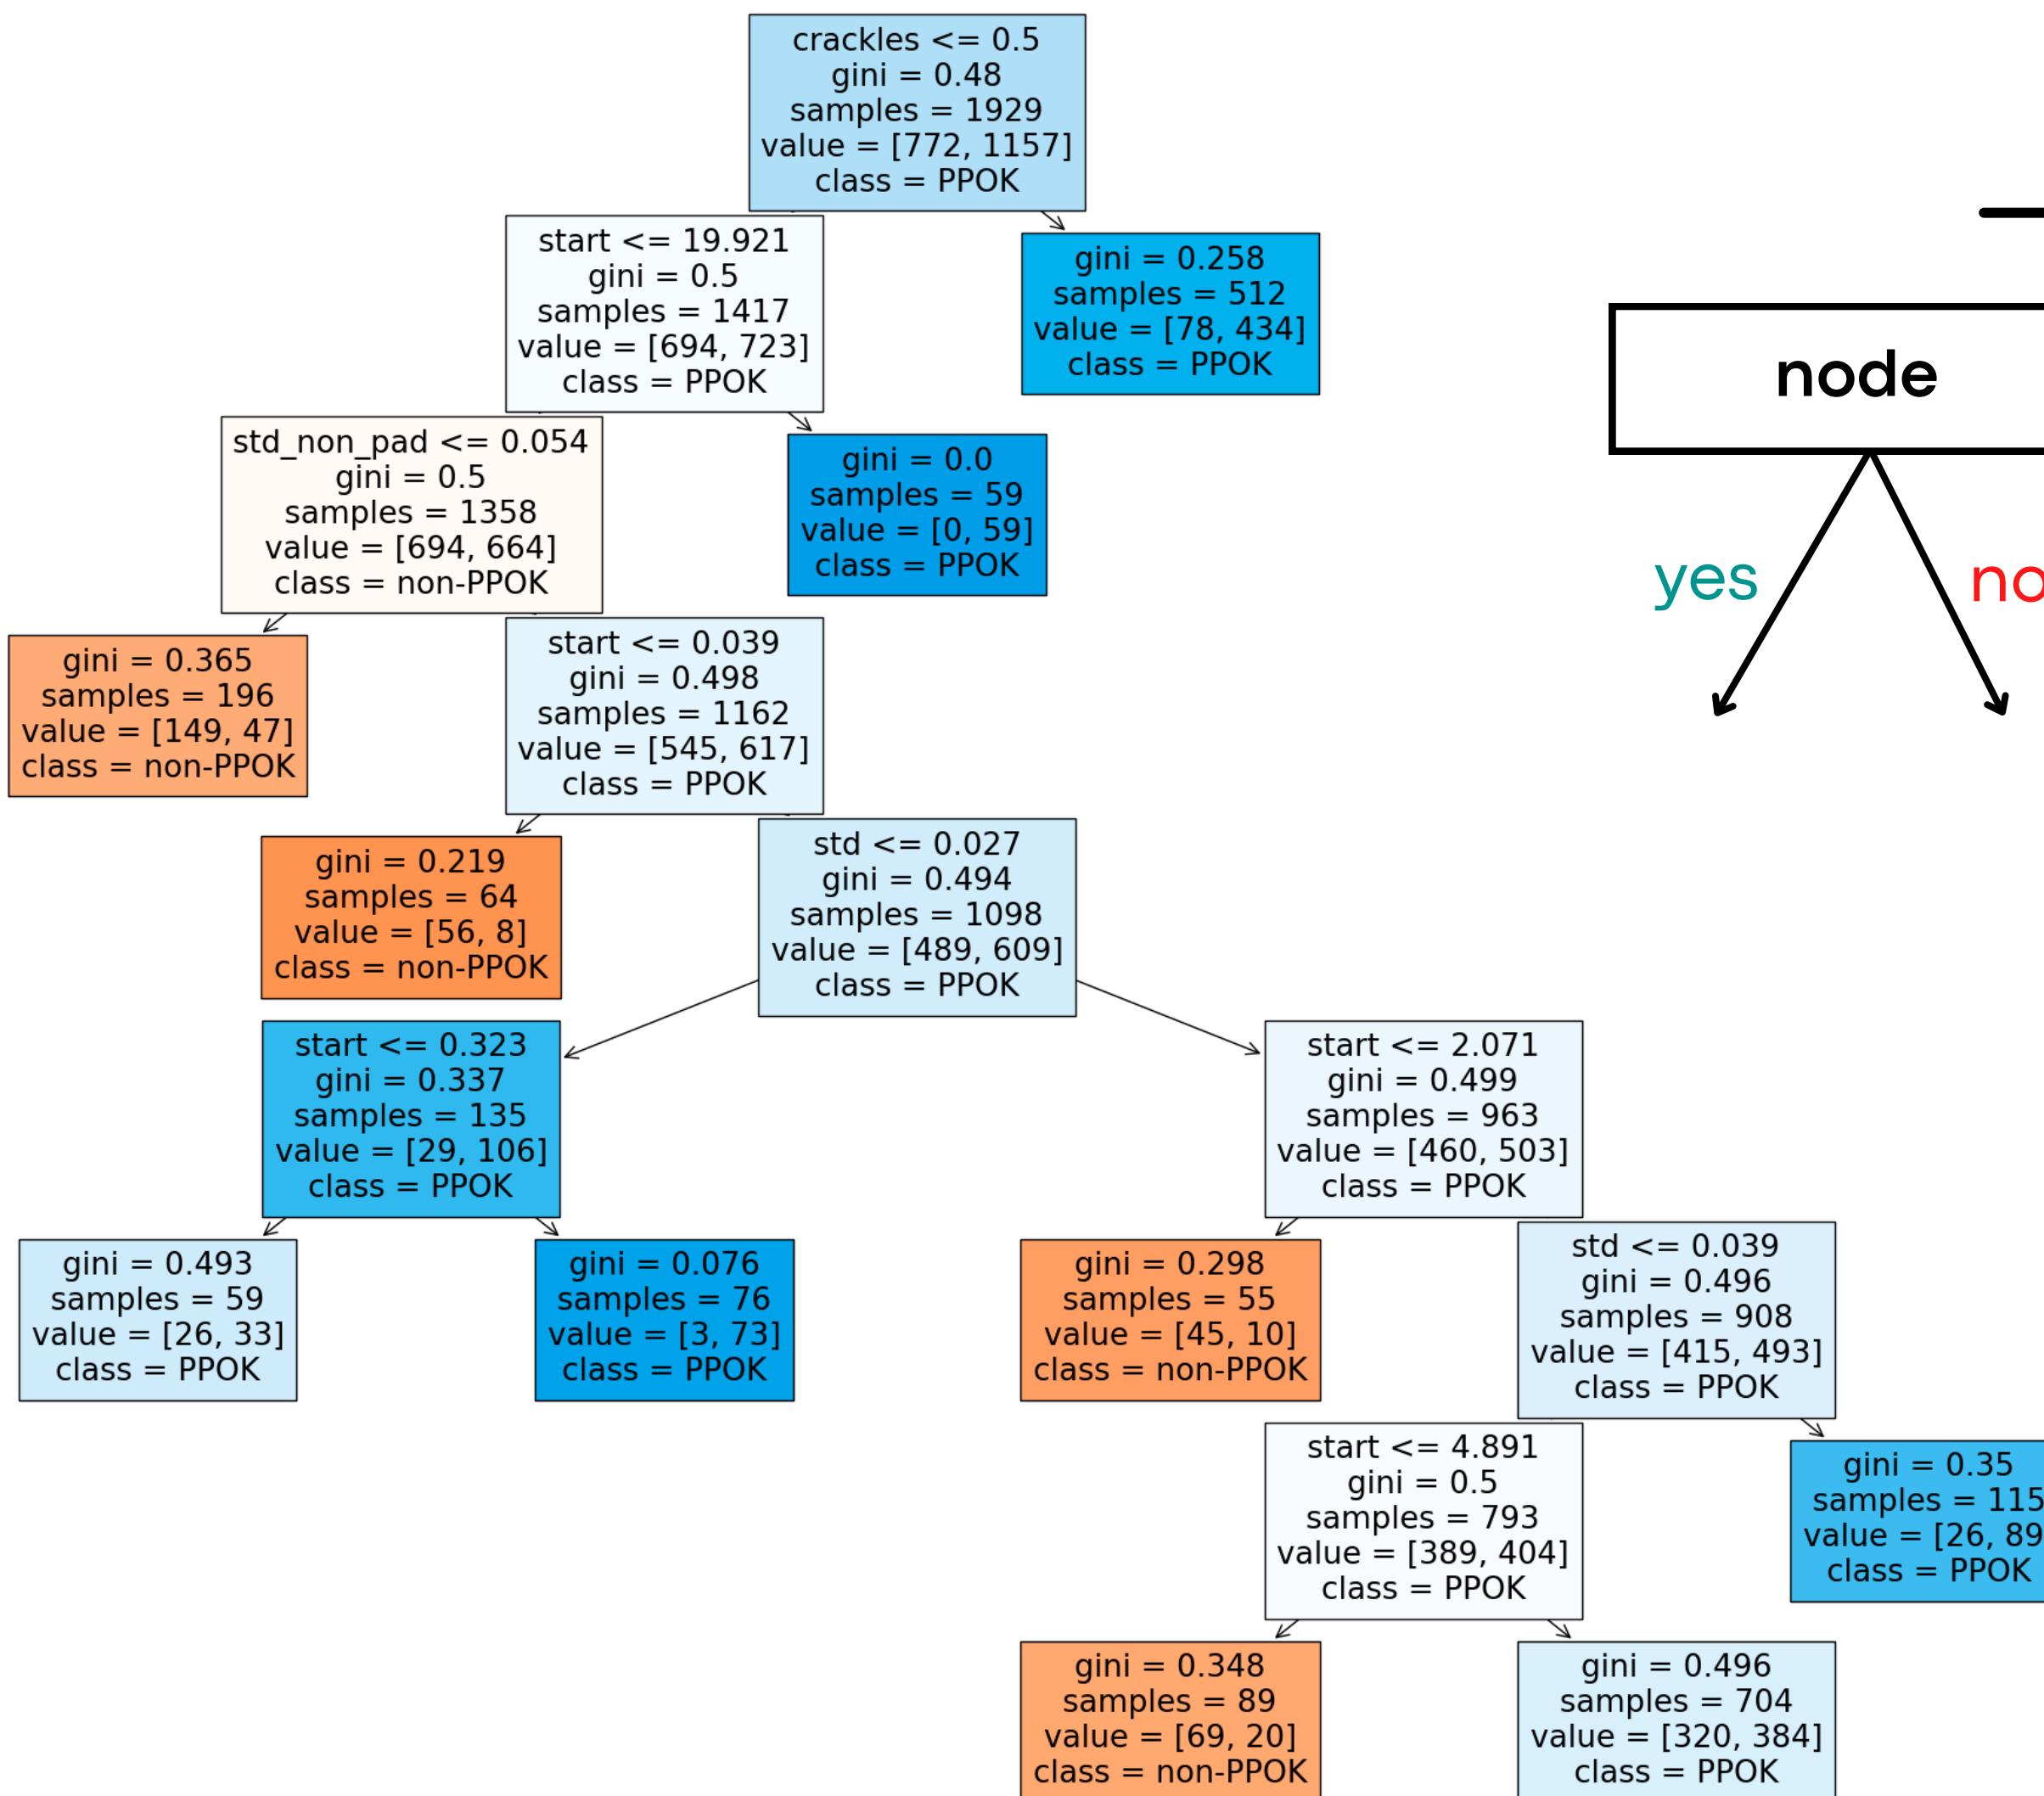
Setelah Feature Importances

INSTITUT TEKNOLOGI BANDUNG



Untuk Interpretasi Model yang lebih
baik, perhatikan gambar decision
tree berikut.





crackles <= 0.5
gini = 0.48
samples = 1929
value = [772, 1157]
class = PPOK

Informasi dari setiap Node:

1. Kondisi Splitting
2. Gini Impurity (lower better)
3. Jumlah Sampel pada node
4. Banyak sampel di setiap kelas
5. Kelas dominan pada Node



SUARA NON-PPOK 



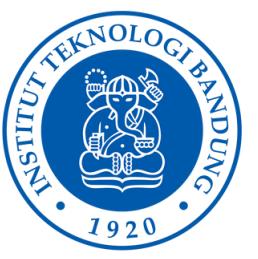
INSTITUT TEKNOLOGI BANDUNG

SUARA PPOK



PERBANDINGAN MODEL

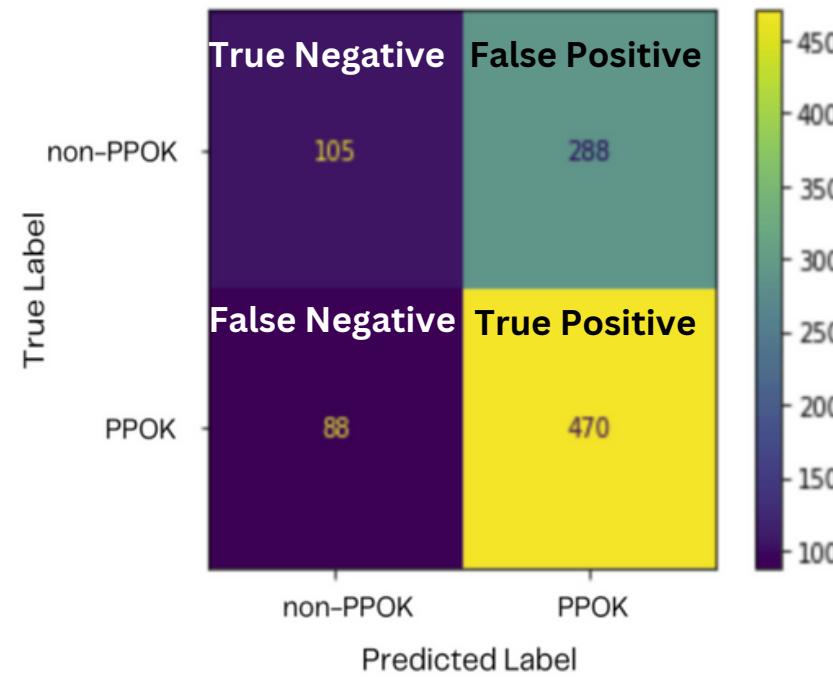
INSTITUT TEKNOLOGI BANDUNG



Hasil evaluasi model CNN pada data test

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	62%	84%	71.3%	60%
Tidak memiliki PPOK (non-PPOK)	54%	27%	36%	

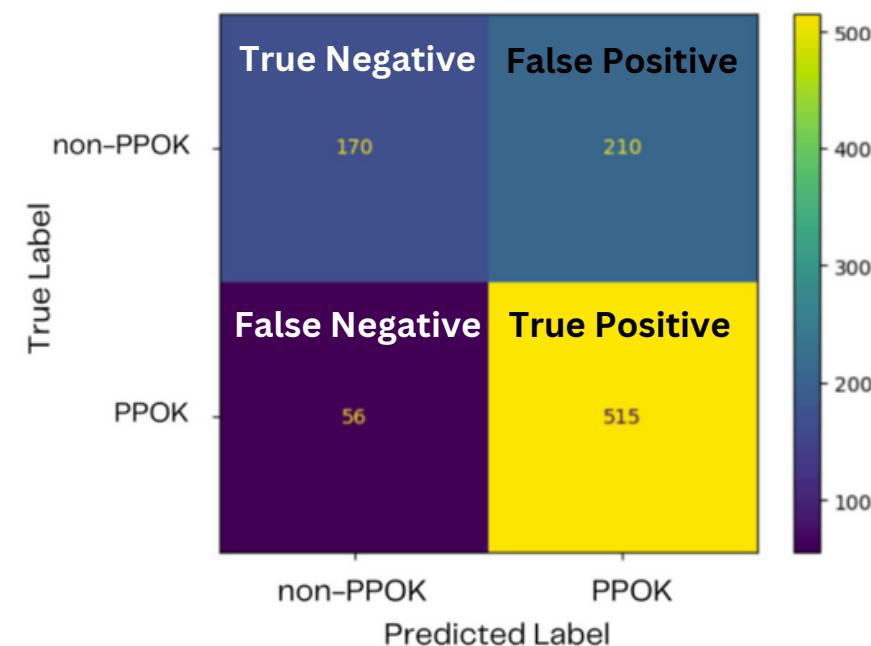
179 detik.



Hasil evaluasi model Decision Tree pada data test

Nilai Prediksi	Precision	Recall	F1-Score	Akurasi
Memiliki PPOK	71%	90%	79%	72%
Tidak memiliki PPOK (non-PPOK)	75%	45%	56%	

0.015 detik.



$$\text{Precision} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Positive}}$$

$$\text{Recall} = \frac{\text{True Positive}}{\text{True Positive} + \text{False Negative}}$$

$$F1\ Score = 2 \times \frac{\text{recall} \times \text{precision}}{\text{recall} + \text{precision}}$$

KESIMPULAN

INSTITUT TEKNOLOGI BANDUNG



1. Model Decision Tree memberikan hasil yang lebih baik dalam mendiagnosa penyakit pernapasa obstruktif kronis berdasarkan paramater yang telah ditetapkan, dengan skor **akurasi yang lebih tinggi 12%**, skor **recall** pada kelas PPOK dan non-PPOK yang **lebih tinggi 6% dan 28%**, serta skor **precision** pada kelas PPOK dan non-PPOK yang **lebih tinggi 9% dan 21%** dibandingkan dengan metode **Convolutional Neural Network (CNN)**.

2. 5 fitur yang paling **berperan penting** dalam menentukan seseorang memiliki PPOK, yaitu variabel independen **start, non_zero, std, std_non_pad, dan crackles**.



- 1. Menambahkan jumlah sampel data yang berkaitan dengan penyakit jantung.**
 - Meningkatkan performa model karena sangat membantu dalam melatih model CNN ataupun Decision Tree.
- 2. Menambahkan lebih banyak variabel-variabel independen, terutama dalam proses ekstraksi fitur dalam bentuk tabular.**
 - Meningkatkan variabilitas dalam sampel, sehingga model dapat menangkap lebih banyak pola, untuk meningkatkan performa model.
- 3. Melakukan hyperparameter tuning dengan metode lain pada model yang telah dibangun.**
 - Meningkatkan performa model, sehingga dengan pengaturan parameter dalam model, dapat menghindari model yang overfitting atau underfitting.
- 4. Melakukan feature scaling sebelum proses pelatihan model, baik dalam ekstraksi data suara, maupun ekstraksi fitur ke dalam data tabular.**
 - Meningkatkan efisiensi model, serta meningkatkan performa model, terutama untuk menghindari ketimpangan skala antar variabel independen

REFERENSI

INSTITUT TEKNOLOGI BANDUNG



Dash, S. (2022, November 2). Decision trees explained-entropy, information gain, Gini Index, CCP pruning.. Medium. <https://towardsdatascience.com/decision-trees-explained-entropyinformation-gain-gini-index-ccp-pruning-4d78070db36c>

Yenigün, O. (2021, September 15). Decision tree parameter explanations. plainenglish.io/blog/decision-tree-parameters-explanations-tuning-a2b0749976e5.<https://plainenglish.io/blog/decision-tree-parameters-explanations-tuning-a2b0749976e5>

Billiau, S. (2022, August 8). From scratch: Permutation feature importance for ML interpretability. Medium. <https://towardsdatascience.com/from-scratchpermutation-feature-importance-for-ml-interpretability-b60f7d5d1fe9>

Short-time fourier transform and chroma features - audiolabs-erlangen.de. (n.d.). https://www.audiolabs-erlangen.de/content/05-fau/professor/00-mueller/02-teaching/2016s_apl/LabCourse_STFT.pdf

Raschka, S. (n.d.). Stat 451 -- introduction to machine learning and Statistical Pattern Classification (fall 2021). Sebastian Raschka, PhD. <https://sebastianraschka.com/teaching/stat451-fs2021/>

Decision tree algorithm in Machine Learning - Javatpoint. www.javatpoint.com. (n.d.). <https://www.javatpoint.com/machine-learning-decision-tree-classification-algorithm>

McFee, B., Raffel, C., Liang, D., Ellis, D., McVicar, M., Battenberg, E., & Nieto, O. (2015). librosa: Audio and Music Signal Analysis in Python. Python in Science Conference. <https://doi.org/10.25080/Majora-7b98e3ed-003>

Roberts, L. (2022, August 17). Understanding the mel spectrogram. Medium. <https://medium.com.analytics-vidhya/understanding-the-mel-spectrogram-fca2afa2ce53>



TERIMA KASIH

Thank You | 谢谢 | 고맙습니다 | ありがとうございました | Danke | Merci | Gracias

